Quantitative Analysis of Multi-Component Organic Solutions Using Raman Spectroscopy: Effects of Analytical Pathways and Dataset Configurations

Haokai Yang[1] and Hongwang Lu*[1]

[1]School of Physics, Shandong University, Jinan, China

*Email: lu@sdu.edu.cn

摘要

基于拉曼光谱的定量分析可靠性取决于分析路径的选择与数据集配置的合理性，但二者的相对重要性及交互效应尚缺乏在同一实验体系下的系统考察。本文以多组分有机溶液体系为实验平台，系统研究了两类方法论因素对定量预测泛化能力的影响：一是分析路径，涵盖光谱预处理策略（高斯背景校正、非对称最小二乘、扩展乘性散射校正及其与面积归一化/向量归一化的组合）、回归模型选择（偏最小二乘PLS vs. 一维卷积神经网络1D-CNN）与输出维度（单输出 vs. 多输出）；二是数据集配置，从化学多样性（训练环境中的物种数量）、样本规模与单样本数据点个数（作为数据增强替代方案）三个层面变化训练数据。所有模型均以Huber损失为优化目标，并通过交叉折测试预测（CFT）与含化学异质性样本的独立测试集进行评估。结果表明，1D-CNN在本研究评测的全部配置下均显著优于PLS，高斯背景校正结合面积归一化（gs-na）是最鲁棒的预处理策略，多输出架构则借助跨分析物的共享表示有效抑制了单输出模型的过拟合；在数据集配置方面，三个层面的影响呈现清晰优先级，其中扩展环境化学多样性可使预测精度提升约19%，而单纯增加单样本数据点个数仅带来不足8%的边际改善。此外，目标分析物的本征拉曼活性（特别是特征峰的锐度与光谱隔离程度）是决定预测精度上限的关键物理化学因素。这些发现为复杂混合物拉曼定量分析的方法论设计提供了系统性指导。

Keywords

Raman spectroscopy, quantitative analysis, multi-component organic solutions, one-dimensional convolutional neural network, partial least squares regression, spectral preprocessing, single- and multi-output regression, dataset design

引言

有机或无机混合物中特定化学成分的定量测定，是化学工程、生物学和医学诊断等领域的基础性任务。拉曼光谱作为一种基于分子振动信息的无损分析技术，能够提供样品的特征"指纹"光谱，支持非侵入式检测，在物质定性识别和定量分析方面具有独特优势 [1]。一个典型的拉曼定量分析工作流程

通常包含数据质量控制（异常值剔除、强度校准）、光谱预处理（平滑、背景校正、归一化）、模型构建与优化，以及最终在测试数据上进行预测等连续阶段 [2]。在这一流程中，两类选择对最终预测性能具有决定性影响：一是**分析路径**，涵盖回归算法的选择（从经典的偏最小二乘PLS回归 [3] 到现代的卷积神经网络CNN [4, 5]）、光谱预处理策略以及输出维度的设计；二是**数据集配置**，包括训练数据的化学多样性、样本规模以及单样本数据点个数的安排。

大量文献已对分析路径中的个体因素进行了研究，但多聚焦于单一维度。Zarei等人 [6] 在复杂有机–矿物混合物体系中系统比较了PLS与CNN模型对氨基酸组成的预测性能，并考察了荧光背景和矿物峰干扰下预处理策略（背景去除、Z-score归一化）的有效性，发现模型性能高度依赖于预处理选择和基质复杂度；Bjerrum等人 [7] 报告了通过数据增强对红外光谱CNN模型的少量提升；Ma等人 [8] 则评估了多种预处理方法在拉曼定量分析中的效果。然而，现有研究倾向于孤立地考察单个因素，缺乏在同一实验体系中对**分析路径**与**数据集配置**进行系统解耦的方法论研究，使得各因素间的相对重要性及交互效应仍不明确。

为填补上述空白，本文从方法论角度出发，在一个统一的多组分有机溶液实验体系中，分两个方向系统地考察影响拉曼定量预测泛化能力的因素：其一，分析路径的选择——预处理方法（高斯背景校正、非对称最小二乘、扩展乘性散射校正与面积/向量归一化的组合）、回归模型（PLS vs. 1D-CNN）以及输出维度（单输出 vs. 多输出）如何交互影响模型的预测精度与泛化鲁棒性；其二，数据集配置的设计——训练数据的化学多样性（四组分环境 vs. 六组分环境）、样本规模以及单样本数据点个数（作为数据增强替代方案）如何共同塑造模型的泛化能力，具体而言，环境化学多样性的扩展能否提供超越单纯数据复制的正则化效益。为探讨上述问题，本研究以含有六种不同拉曼活性的代表性有机化合物（乙二醇EG、聚乙二醇PEG200、乙酸AA、1,2-丙二醇PG、二甲亚砜DMSO和二乙二醇单乙醚DEGEE）的多组分溶液为实验平台，构建了五种化学复杂度和样本规模各异的子数据集配置，在预处理方法组合、输出维度和平均化处理的全矩阵下训练了PLS和1D-CNN模型，所有模型均通过交叉折测试预测（CFT）评估，并在含有训练数据中不存在的化学物种的独立测试集上严格测试泛化能力。除预测精度外，本文还从光谱学原理和统计学视角提供了阐释性分析，以期为复杂混合物拉曼定量分析的方法论设计提供系统性指导。

数据集与实验设计

光谱采集

使用Ocean Optics拉曼光谱仪采集拉曼光谱，信噪比为1,000:1，激发激光波长为785 nm。拉曼强度以任意单位（a.u.）报告，波数范围为0–3056 cm^{-1}，每条光谱含1039个采样点。采集前先预热15分钟。样品溶液置于透明的玻璃或石英试管中，出光处与入光处在垂直于试管轴线方向的同一侧；为排除剩余环境光及玻璃/石英试管本身的背景光，采集在暗环境条件下进行，并在正式采集前先以空试管采集暗光谱以扣除背景。光谱采集时，激发激光从透明试管侧面入射。

数据集描述

本研究选择的六种有机液体——乙二醇（EG）、分子量200的聚乙二醇（PEG200）、乙酸（AA）、1,2-丙二醇（PG）、二甲亚砜（DMSO）和二乙二醇单乙醚（DEGEE）——均互溶、不挥发或低挥发、无毒或低毒、粘度较低。由于1,2-丙二醇与聚乙二醇 200的特征峰与相邻组分高度重叠、且其本征拉曼

表 1: 五种数据集配置的构成、样本数与组分环境。A组=乙二醇（EG）、聚乙二醇（PEG200）、乙酸（AA）与1,2-丙二醇（PG）；B组=二甲亚砜（DMSO）与二乙二醇单乙醚（DEGEE）。

数据集	样本来源	样本数	组分环境	组分数
D1	样本数据集1（全量）	99	A组	4
D2	样本数据集1（PEG≤50%）	82	A组	4
D3	样本数据集1（含PEG样本全部剔除）	41	A组	3
D4	样本数据集1+2（全量）	136	A组+B组	6
D5	样本数据集1+2（PEG、DEGEE≤50%）	111	A组+B组	6

强度相对较弱，它们难以被有效建模，相关预测图像在辅助材料中给出；正文部分仅对乙二醇（EG）与乙酸（AA）两种分析物进行建模与讨论。各化合物的拉曼活性 [1] 差异显著：乙酸的拉曼活性最强，其特征峰在混合物光谱中占据主导地位。各化合物的特征拉曼峰位置及相对强度详见辅助材料表 S1，纯物质拉曼光谱对比见图 4(a)。共制备了136个不同的物理样本，进行了714次独立光谱测量，样本点与浓度配置的对应关系见随稿提交的补充数据文件 `sample_concentration_136.csv`（其说明见文末"Supporting Information"）。两个样本子集的构成如下：样本数据集1含99个样本，其化学溶液在乙酸与乙二醇之外添加了PEG200和PG两种干扰溶质；样本数据集2含37个样本，在乙酸与乙二醇之外添加了PEG200、PG、DMSO和DEGEE四种干扰溶质。两个样本子集的溶液配置方案互不重合，且数据集2中的所有样本均包含DMSO和DEGEE两种干扰溶质。该配置同时保证了非零浓度样本的浓度近似线性分布。激光功率分别设置为100、200和300（激光器未标注标定单位，故以上数值为未标度的相对功率量级），每个功率水平下重复测量1–3次，以模拟不同的激光环境条件对光谱信号的影响。每个物理样本在上述功率条件下共计重复测量5–7次。

训练与验证数据集

为了探求数据集配置对模型预测性能的影响，构建了五种数据集配置，以系统性地改变化学多样性和样本规模，各数据集的构成与规模汇总于表 1。

全部五个数据集均用于预测目标分析物的浓度。数据集D1–D3（四组分环境）与D4–D5（六组分环境）之间的比较，旨在探究化学多样性（环境组分数）是否影响对乙二醇、乙酸的模型预测性能。D1 vs. D4和D2 vs. D5之间的比较，旨在探究六组分化学环境相对于原始四组分环境，是否影响对原始目标分析物的预测精度。

测试集

将样本数据集2保留为数据集D1、D2和D3的额外独立测试集，进一步划分为两个子集：**测试集1（T1）**（含有乙酸和乙二醇的样本，18个样本）与**测试集2（T2）**（不含有乙酸和乙二醇的样本，19个样本）。这两个测试集仅用于评估在数据集D1、D2和D3上训练的模型（它们是D4和D5的子集，因此不用于这些数据集的测试）。由于测试集中含有D1–D3训练数据中不存在的两种化学物种（B组），因此能够对在较窄化学环境中训练的模型的泛化能力和鲁棒性进行严格评估。

方法

异常值检测与剔除

在测量过程中，人为失误——包括样本标记错误和溶液浓度配制错误——可能导致某些数据点的光谱与其标称浓度不匹配，构成异常值。我们采用了两阶段的异常值检测流程。首先，受马氏距离方法 [9]启发，用光谱向量的余弦相似度和大小评估样本内相似度；相似度评估公式、阈值和结果见辅助材料图 S5。样本29因样本内重复性低而被移除。其次，对所有剩余数据施加高斯背景校正和向量归一化预处理，然后使用PLS和CNN模型进行交叉折测试预测（CFT）。随后应用多元学生t分布分析 [10]，检测阈值为3σ，剔除了样本4、16、37、49、53和73。

预处理方法

拉曼位移范围选择

300–1500 cm^{-1}的光谱区间包含大多数有机化合物的特征振动指纹。在进一步预处理之前，所有光谱均截取至该区间（343个采样点）。

光谱预处理

遵循Ryabchykov等人 [2] 的分类体系，本研究采用五种光谱预处理方法，并以"基线校正–归一化"的组合方式施加。基线校正方法包括：非对称最小二乘基线校正（*asls*，$\lambda = 10^5$，$p = 0.01$，迭代$n_{\mathrm{iter}} = 10$次 [2]）、扩展乘性散射校正（*emsc*，参考光谱取均值$R_{\mathrm{ref}} = \mathrm{mean}$，多项式阶数$M = 2$ [2]）以及高斯形式的基线校正（*gs*，高斯平滑，$\sigma = 20$ [11]）；归一化方法包括面积归一化（*na*）与向量归一化（*nv*）。

光谱预处理的顺序和配置会很大程度上影响模型建模效果，我们在实验中进行了系统性的探究。需要说明的是，本研究的预处理由基线校正与归一化构成，并未额外引入独立的**平滑处理**作为单独的预处理环节。平滑处理虽为拉曼分析中普遍采用的一步，但鉴于其在实验条件下对预测性能的影响很小，故未单独施加；上述高斯形式的基线校正（*gs*）在此仅作为基线校正手段使用，而非独立的平滑处理环节。为避免歧义，本研究所使用的基线校正方法公式见辅助材料。

训练验证协议与样本内平均化(数据增强替代反方案)

训练验证协议与样本内平均化（数据增强替代方案）

为探究通过重复测量进行数据增强是否为光谱深度学习带来显著收益（如Bjerrum等人 [7] 所报告的），我们引入了样本内平均化处理：经此处理后，同一物理样本的所有重复测量在预处理前进行平均。需要指出的是，该处理并不像 [12]中的数据增强那样只对训练集进行扩展，而是将整个数据规模由136个样本、714条光谱直接压缩至136个样本、136条光谱（即每个样本仅保留1条平均光谱）；未平均化的条件则保留所有重复测量，作为通过复制实现数据增强的替代方案，用于模拟真实场景下的数据增强情形。

为进行真实场景下的对比，对于未平均化的情形，我们在预测完每个光谱后进一步在样本内部聚合，从而得到该样本的预测值及其标准差；最终结果均以每个独立物理样本为单位，符合物理测量的

实际情况。为防止光谱分析深度学习中常见的数据泄露 [13]、避免模型在测试时高估泛化性能，数据分割严格按照测量结构进行，处理方式与文献 [12]一致：来自同一物理样本的重复光谱在统计上并不独立，故被合并至同一数据集，确保训练集、验证集与测试集的溶液配置完全互斥。与此一致，本文采用确定性的PyTorch设置、固定的随机种子以及严格的分组数据划分方式，使每个样本的所有副本始终处于同一数据集中，从而避免数据泄露、确保测试结果真实反映模型对未知样本的泛化能力。

所有模型均使用交叉折测试预测（CFT）[2] 进行训练和评估，以确保对泛化能力进行稳健的评估，其设定与文献 [14]中辅助材料的方法一致。具体而言，交叉折测试预测（CFT）将数据划分为5折，每一折轮流充当测试集，其余折用于训练与验证。由于本实验的样本数约为 [14]中13个样本的10倍，故并未套用其给定的折分方案，而是改用固定随机种子下的确定性数据分割；同时，为避免纯随机分割可能造成的单折中某种浓度的零浓度样本占比过多、从而导致训练/验证/测试结果不典型的情况，本文采用 [15]的相似度算法进行分组式数据分割。另外，对于外推测试集评估（即未参与交叉折测试预测的测试集T1、T2），将交叉折测试预测产生的五个模型分别对测试集样本进行独立预测，再取五个预测值的简单算术平均作为该样本的最终预测结果；所有报告的测试集指标均基于此集成平均预测值计算。数据分割与训练过程的详细说明见辅助材料。

损失函数与评估指标

本研究通篇采用四种评估指标：决定系数（R^2）、均方根误差（RMSE）、平均绝对误差（MAE / L1）和Huber损失（亦称Smooth L1损失）。均为先对样本内重复测量取预测值的平均，再以样本为单位计算各项指标，与真实测量中多次采集取平均值的做法保持一致。 Huber损失结合了MSE对小残差和MAE对大残差的优势，对异常值具有更强的鲁棒性 [16]。Huber损失以δ为阈值参数，而Smooth L1损失以β为阈值参数，在默认取值$\delta = \beta = 1.0$下两者的公式等价（实现口径见 [17]）。本实验取$\delta = 1.0$。 Huber损失作为PLS组分选择和CNN超参数调优及早停的唯一优化目标。

偏最小二乘（PLS）回归

采用PLS回归 [3] 对光谱特征与目标分析物浓度之间的映射关系进行建模。模型的构建与验证使用Python语言中`scikit-learn`库的`model_selection`模块实现。最优潜变量个数通过最小化验证折上的Huber损失进行选择。PLS潜变量选择过程的代表性曲线见辅助材料图 S4。

一维卷积神经网络（1D-CNN）

1D-CNN架构遵循Bjerrum等人 [7] 和Kiranyaz等人 [5] 确立的设计原则，包含两个一维卷积层，后接一个全连接层。在多输出配置下，输出层维度调整为与目标分析物数量匹配。训练采用**Adam优化器**，最大训练轮次`epochs = 500`，早停耐心值`patience = 100` [18]，使用PyTorch实现 [19]。网络结构示意图见辅助材料图 S1。

贝叶斯超参数优化

超参数使用**Optuna**框架进行优化，以**TPE（Tree-structured Parzen Estimator）**采样器作为默认贝叶斯优化器。优化目标为最小化验证集Huber损失。优化器共执行15次优化试验，其中前5次

用于初始随机探索（若设为0则全程均为贝叶斯优化），每组超参数重复训练2次并取均值作为该试验的得分。

与光谱分析领域常见的仅优化网络架构参数的做法不同，本研究的贝叶斯优化将**学习率**和**训练批次大小**一并纳入搜索空间。这两者对训练稳定性和最终泛化性能有显著影响，单独优化架构参数而固定学习率可能导致次优解。超参数优化过程的可视化见辅助材料图 S2，代表性训练曲线见辅助材料图 S3。

在全部15次试验×2次重复的优化过程中，观察到以下一般规律：表现良好的模型中，学习率通常收敛于0.001–0.002区间，过高（>0.0025）或过低（<0.0008）均导致验证损失显著上升；训练批次大小在32–64范围内对性能影响不敏感，但过大的批次（≥128）在样本数较少的平均化数据集上出现泛化退化；第一卷积层滤波器数（C1_K）的最优值集中在8–12个，第二卷积层（C2_K）为16–24个，表明较深的第二层需要更多滤波器来捕获高层光谱特征；卷积核大小方面，较小的核（C1_S为8–16，C2_S为16–32）普遍优于大核，提示本数据集的光谱特征以局部振动模式为主；全连接层神经元数（DenseN）在64–96范围内表现稳定； Dropout比率的最优值集中于0.03–0.07，过高的Dropout（>0.08）会导致欠拟合。超参数优化过程的可视化见辅助材料图 S2，代表性训练曲线见辅助材料图 S3。

结果

光谱数据概览

本研究共采集了136个物理样本的714条独立拉曼光谱（每个样本5–7次重复测量），光谱波数范围为0–3056 cm^{-1}，截取至300–1500 cm^{-1}指纹区进行分析（343个采样点）。所构建的五个子数据集在化学复杂度和样本规模上呈梯度分布：D1（99样本/4组分）至D4（136样本/6组分），其中D3（41样本/3组分）用于检验极端样本稀疏条件下的模型行为，D2和D5则通过浓度约束进一步细化子空间划分。两个独立测试集（T1: 18样本，T2: 19样本）含有D1–D3训练数据中不存在的B组化学物种（DMSO和DEGEE），用于评估模型的分布外泛化能力。

预处理流程演示

预处理流程由三个连续步骤组成：拉曼位移范围截取、背景校正和归一化。图 1以样本 111为例展示了光谱依次经过原始光谱、基线拟合、扣除基线及面积归一化各步骤的演变过程。

结果部分的命名约定

为简洁呈现多维实验矩阵的结果，本文通篇使用以下统一缩写。数据集以D1–D5表示五种训练/验证数据集配置（定义见"训练与验证数据集"一节）；测试集以T1、T2表示两种独立外推测试集（定义见"测试集"一节）；*multi*与*single*分别表示输出层维度与目标分析物数量匹配的多输出回归、以及每次仅预测单一目标分析物的单输出回归；*nonavg*与*avg*分别表示保留同一物理样本的所有重复测量、以及同一物理样本的重复光谱在预处理前取平均；*CFT*（交叉折测试预测）指数据划分为5折、每折轮流充当测试集、其余折用于训练与验证，其指标为全部样本依次处于测试折位置时的预测性能汇总，衡量对未参与调优样本的外推预测能力，不同于用于超参选择与早停的验证集；*Best*表示在同时于CFT与

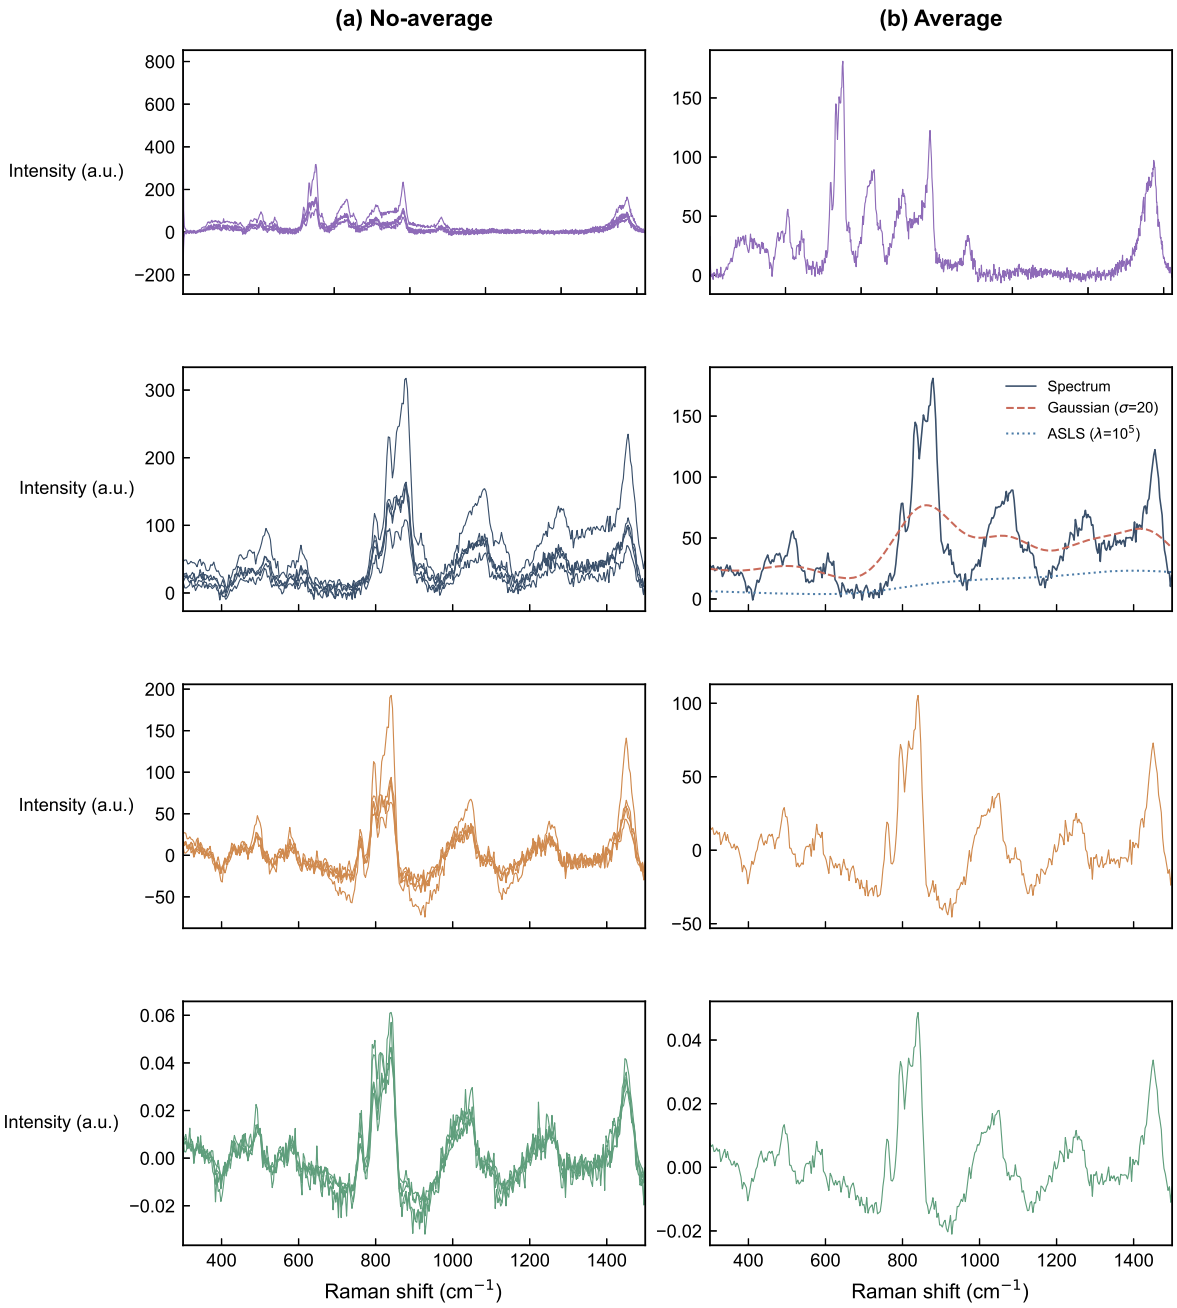


图 1: 光谱预处理全流程演变（以样本 111 为例）。四行分别展示原始光谱（Step 1）、基线拟合（Step 2，Gaussian 与 ASLS）、扣除基线（Step 3）及面积归一化（Step 4）。左列（a）为未平均化的五次重复测量，右列（b）为均值化后的单条光谱。Step 2 右图中同时绘出 Gaussian（$\sigma = 20$，红色虚线）与 ASLS（$\lambda = 10^5$，蓝色点线）两种基线估计以资对比。

表 2: PLS与1D-CNN在交叉折测试预测集（CFT）和测试集上的性能比较（Huber损失，乙酸/乙二醇）。

评估集	PLS		1D-CNN	
	乙酸	乙二醇	乙酸	乙二醇
CFT (D4-nonavg-single-Best)	3.60	5.22	2.34	3.51
Test (D1-nonavg-multi, T1)	8.27	10.35	3.62	6.98
Test (D1-nonavg-multi, T2)	6.22	9.49	2.98	1.81

表 3: 预处理方法对1D-CNN预测性能的影响（Huber损失，乙酸/乙二醇），涵盖交叉折测试预测集（CFT）和两个独立测试集。数据集：D1-nonavg-multi。**绿色**表示该单元性能较优（Huber损失较低，颜色越深越优），**红色**表示性能较差（Huber损失较高，或超出显示上限>10/>15）；每列最优值以粗体标出。

预处理	CFT (D1-nonavg-multi)	测试 T1	测试 T2
asls+na	8.90 / >10	14.64 / >15	3.58 / >10
asls+nv	3.46 / 4.98	4.99 / 7.65	6.67 / 10.95
emsc+na	3.43 / 5.33	>15 / >15	1.37 / 2.57
gs+na	**3.17** / **4.78**	**3.10** / 11.46	**2.21** / **3.93**
gs+nv	3.16 / 4.85	3.19 / **10.08**	4.72 / 5.16
na	>10 / >10	>15 / >15	>10 / >10
nv	3.55 / 4.93	6.19 / 12.62	7.23 / >10
none	3.53 / 5.87	7.37 / >15	0.97 / >10

测试集上表现良好的方法组合（asls+nv、gs+na、gs+nv）中，选取验证集Huber损失最低者。例如，标识 `"D4-nonavg-multi-Best"` 依次对应"数据集4、未平均化、多输出、取良好预处理中的最佳值"。

此外，六种化合物的缩写如下：乙二醇（EG）、聚乙二醇 200（PEG200）、乙酸（AA）、1,2-丙二醇（PG）、二甲亚砜（DMSO）、二乙二醇单乙醚（DEGEE）。

算法比较：PLS vs. 1D-CNN

在本研究所评测的全部配置条件下，1D-CNN模型均显著优于PLS回归。代表性结果见表 2，各配置下的完整预测效果汇总见辅助材料表 S3。在交叉折测试预测集（CFT，D4-nonavg-single-Best）上，1D-CNN将乙酸的Huber损失从3.60降至2.34，将乙二醇的Huber损失从5.22降至3.51——分别降低约35%和33%。在独立测试集（D1-nonavg-multi-Best）上，性能差距急剧扩大：PLS对乙酸/乙二醇（T1）的Huber损失分别为8.27/10.35，对乙酸/乙二醇（T2）为6.22/9.49，而1D-CNN分别达到3.62/6.98和2.98/1.81。基于此显著差异，后续分析将集中在1D-CNN模型上。

预处理方法的影响

在所评估的八种预处理策略之间，预测性能存在显著差异（表 3）。以样本 111为例的预处理全流程演变见图 1。 高斯背景校正结合面积归一化（gs-na）组合总体上是鲁棒性最强的策略，在六个评估列中的五个取得了最优或接近最优的性能。在大多数不同配置中，排名gs-na > gs-nv ≈ asls-nv。在大多数预处理配置下，乙酸的预测精度系统地优于乙二醇。此外，无预处理（none）条件下，1D-CNN在

表 4: 多输出（multi）与单输出（single）1D-CNN在交叉折测试预测集（CFT）和测试集上的性能比较（Huber损失）。全部结果未施加样本内平均化。每格为乙酸 / 乙二醇的 Huber 损失；**绿色**表示同一（数据集、指标）下损失较低（较优）者，**红色**表示损失较高（较差）者——注意绿色在 CFT 列集中于单输出、而在含目标分析物的外推测试集 T1 上集中于多输出，直观体现了单输出的过拟合倾向。

数据集	输出	CFT		T1		T2	
		乙酸	乙二醇	乙酸	乙二醇	乙酸	乙二醇
D1	multi	3.32	4.76	3.62	6.98	2.98	1.81
	single	2.70	4.19	6.37	9.14	0.87	2.84
D2	multi	3.53	4.41	2.45	6.91	2.47	3.63
	single	2.84	4.12	5.04	8.81	1.45	3.75
D3	multi	3.70	4.62	6.59	12.94	16.63	14.14
	single	3.15	3.62	5.68	11.85	9.99	12.22
D4	multi	2.67	3.67	—	—	—	—
	single	2.34	3.51	—	—	—	—
D5	multi	2.56	3.69	—	—	—	—
	single	2.26	3.54	—	—	—	—

交叉折测试预测（CFT）上虽能有效拟合（Huber 3.53/5.87），但向测试集泛化时出现严重退化（测试集T1上7.37/>15）。

输出维度的影响

单输出模型表现出过拟合倾向：虽然在交叉折测试预测集（CFT）上始终取得较低的Huber损失，但这一优势并未传递到独立测试集，在若干情况下反而伴随泛化性能的下降（表 4）。过拟合效应体现在含目标分析物的化学异质性测试集T1上（表 4）：在数据集1、2上，单输出模型的误差相对多输出模型普遍更高（乙酸在T1上为6.37/5.04 vs. 3.62/2.45，约为多输出的1.8–2.1倍；乙二醇为9.14/8.81 vs. 6.98/6.91，约1.3倍），而单输出模型在这些配置的交叉折测试预测（CFT）上反而更低（乙酸2.70/2.84 vs. 3.32/3.53）；相反，在目标分析物缺失的测试集T2上，单输出模型能够更准确地预测近零浓度（如数据集1、T2上乙酸为0.87 vs. 2.98）。另外，在所有数据集中，目标分析物浓度为零的样本的预测精度显著高于非零样本。

数据集尺度的影响

为系统考察数据集尺度对模型泛化能力的影响，我们从三个层面改变训练数据的构成：**样本数**（通过调整数据集中的样本总数，如D1的99个 vs. D3的41个）、**环境化学多样性**（通过向训练环境中引入额外的化学背景物种，即D1–D3四组分环境 vs. D4–D5六组分环境）以及**单样本数据点个数**（通过对同一物理样本的多次光谱测量取平均 avg 或保留全部重复 nonavg，作为数据增强替代方案，分别将数据规模由136个物理样本、714条光谱压缩/扩展至136个样本、136条光谱）。

从表 5可以看到，环境化学多样性的扩展对预测精度的提升最为显著。将训练化学环境从四组分（D1–D3）扩展到六组分（D4–D5），对原始目标分析物（乙酸和乙二醇）的聚合Huber损失从约3.72降至约3.01（降幅约19%）。值得注意，仅训练样本数量并非主要驱动因素：在同一化学环境内部，样本数的调整（D1→D2，99→82个样本；D4→D5，136→111个样本）在交叉折测试预测（CFT）与外推测试上带来的变化均不大；相比之下，D1（99个样本）与D5（111个样本）的样本数差异并不显著，其聚合Huber损失却从约3.72大幅降至约3.02。这一对比更可能源于D1与D5之间环境化学多样性的差

表 5: 数据集尺度对1D-CNN聚合Huber损失的影响。表中数据为特定数据集与平均化处理组合下，多/单输出、乙酸/乙二醇4个Best值的平均交叉折测试预测（CFT）Huber损失。

数据集	Huber（非平均化）	Huber（平均化）	样本数	组分数
D1	3.72	3.74	99	4
D2	3.72	3.97	82	4
D3	3.95	4.02	41	3
D4	3.01	3.20	136	6
D5	3.02	3.18	111	6

异（四组分 vs. 六组分），而非样本数量的单纯增加——更严格的因果分离有待通过保持其余维度不变的控制变量实验作进一步验证。此外，D3（41样本）与D4（136样本）在交叉折测试预测（CFT）上的Huber损失差异不大，但测试集泛化表现对化学多样性高度敏感。

单样本数据点个数的增加（即nonavg条件，数据规模约为平均化处理的5–6倍）仅带来了有限的改善（聚合Huber损失下降不足8%）。综合三个层面的比较，数据集尺度对泛化能力的影响呈现优先级：环境化学多样性 > 样本数 > 单样本数据点个数。

预测可视化

图 2展示了乙酸（AA）和乙二醇（EG）在各自最佳配置下于**交叉折测试预测（CFT）**上得到的KDE密度着色预测散点图： AA采用1D-CNN、gs+na预处理、多输出、未平均化、数据集D4；EG采用1D-CNN、gs+nv预处理、多输出、未平均化、数据集D4。由于所有样本均经由严格的交叉折测试预测流程进行评估——每一折轮流充当测试集、其余折用于训练与验证——因此图中结果反映的是模型对未参与调优样本的真实外推能力，具有更高的严谨性与可信度。 AA的汇总指标（交叉折测试预测，CFT）为：Huber损失 1.87，MAE 2.18，R^2 0.975，RMSE 4.40；EG的汇总指标（CFT）为：Huber损失 3.03，MAE 3.34，R^2 0.946，RMSE 6.41。

图 3进一步展示了1D-CNN模型（D1-nonavg-multi-gs+na）在两个独立测试集 T1 与 T2 上的分布外预测表现。上排（T1，同时含乙酸、乙二醇及新化学物种）采用经典的实测–预测散点图，每个物理样本聚合为单一数据点（同一样本同色），并叠加默认 95% 置信区间误差棒（正态分布，由样本内重复测量预测的标准差估计，即 $\pm 1.96\sigma$）；下排（T2，乙酸与乙二醇的真实浓度均为 0）改用按物理样本分组的柱状图，并以横向虚线标出真实值 0，用以直观呈现模型在目标分析物完全缺失时的预测偏移程度。

检测限（LOD）与定量限（LOQ）

为评估两种分析物在低浓度区间的可鉴别能力，我们按定量分析的标准定义计算了检测限（LOD）与定量限（LOQ）： $\mathrm{LOD} = 3.3\,\sigma_0/s$，$\mathrm{LOQ} = 10\,\sigma_0/s$，其中 σ_0 为零浓度样本上模型预测浓度的标准差，s 为模型预测浓度对真实浓度的线性回归斜率。采用与图 2相同的实验配置（数据集 D4，六组分环境，未平均化；乙酸为gs+na、乙二醇为gs+nv），计算结果如下：乙酸（AA）的 $\sigma_0 \approx 0.37$ vol%、$s \approx 1.02$，故其 LOD ≈ 1.2 vol%、LOQ ≈ 3.6 vol%；乙二醇（EG）的 $\sigma_0 \approx 0.89$ vol%、$s \approx 0.95$，故其 LOD ≈ 3.1 vol%、LOQ ≈ 9.4 vol%。这表明乙酸在低浓度区间的可鉴别能力明显优于乙二醇（约2.6倍），与其更强的本征拉曼活性及更隔离的特征峰相一致 [20]。检测限所依据的区间线性拟合与计

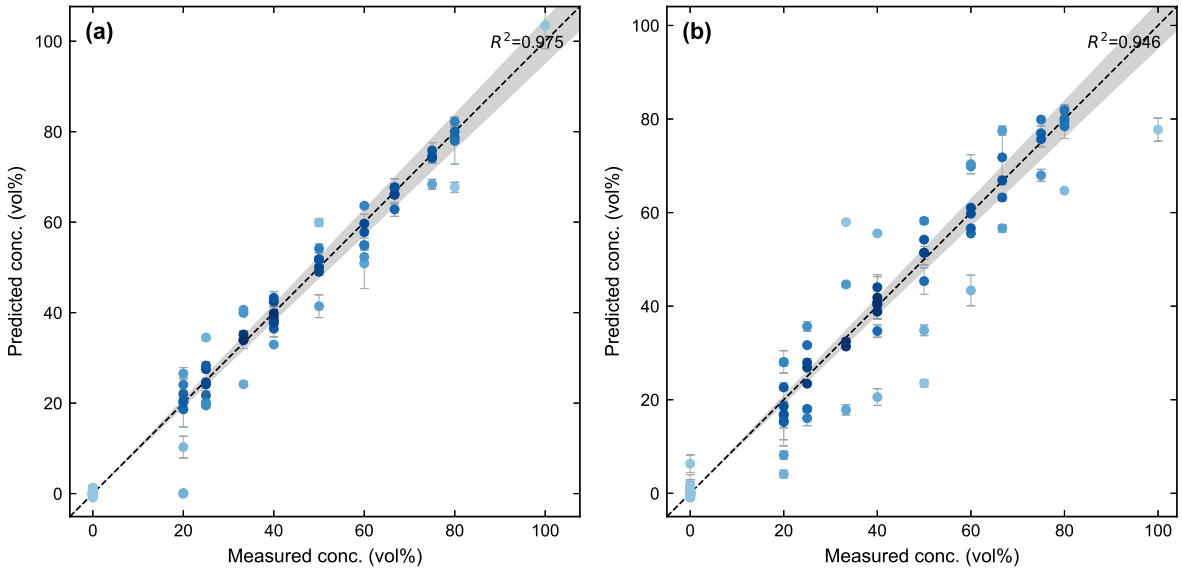


图 2: KDE密度着色预测散点图（交叉折测试预测结果，CFT）。(a) 乙酸（AA）；(b) 乙二醇（EG）。灰色阴影带表示1:1对角线的±5%偏离区间，散点颜色深浅表示局部数据点密度：颜色越深，密度越高。

算细节详见辅助材料。

讨论

数据集配置对模型泛化的影响

实验结果揭示了一个一致且具有实践意义的趋势：训练数据在三个尺度维度上的变化——样本数、环境化学多样性和单样本数据点个数——对模型泛化能力的影响呈现清晰的优先级（表 5）：环境化学多样性影响最大，而单样本数据点个数的增加反而用处不大。这一结论与结果部分"数据集尺度的影响"一节中"环境化学多样性 > 样本数 > 单样本数据点个数"的量化比较一致（聚合Huber损失分别出现约19%的降幅与不足8%的改善）。

环境化学多样性的增加（从四组分扩展至六组分）带来了最显著的泛化改善（表 5）。当模型在较窄的化学空间（数据集D1–D3）中训练时，它可能学会利用在该特定环境中与目标分析物浓度相关、但并非因果诊断性的光谱特征。例如，在四组分混合物中，缺乏某些拉曼活性物种可能导致模型将基线强度变化或溶剂背景特征与浓度变化建立关联。当引入额外的化学物种（数据集D4–D5）时，这些虚假相关性被打破，模型被迫学习真正追踪目标分析物特征振动模式的表示。这一解释与不变风险最小化和领域泛化的原则一致：在环境多样性更丰富的训练数据上进行训练，能够鼓励学习因果性的、而非仅仅是相关性的特征–浓度映射。通过主动向训练集中引入化学多样性（B组物种），而非被动应对基质干扰，可以有效提升模型的泛化鲁棒性。需要强调的是，上述泛化收益来源于化学环境的多样性，**而非**背景峰与目标峰的重叠；相反，特征峰之间的重叠往往不利于定量建模——例如，乙二醇与1,2-丙二醇等物质在A组内部即与相邻组分的特征峰高度重叠，且其本征拉曼强度相对较弱，这正是这些分析物难以被有效建模的重要原因。而在外推测试中，B组物种（DMSO和DEGEE）的特征峰并未与乙酸高度孤立的 892 cm^{-1}峰形成显著重叠，因此未对乙酸产生强烈干扰，故乙酸在含新化学物种

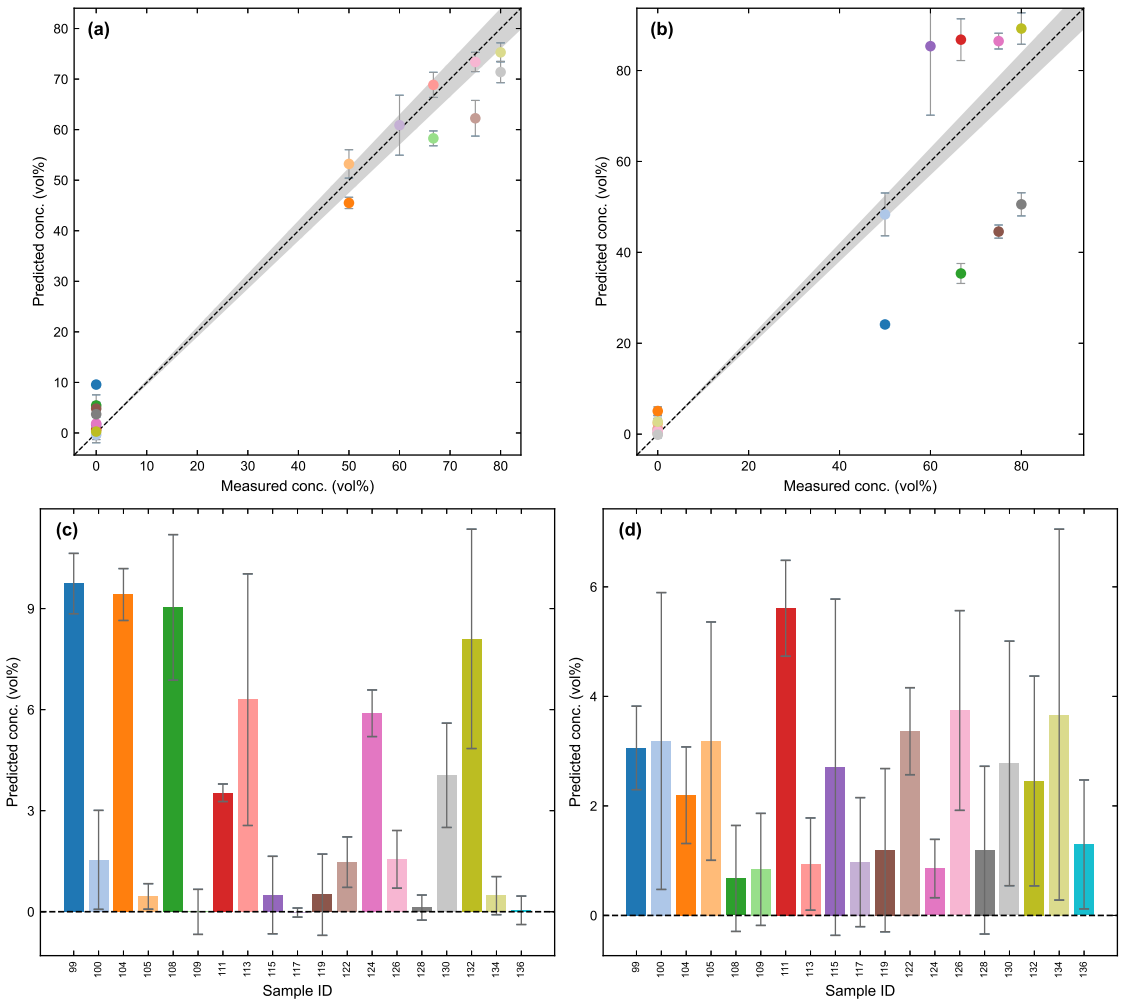


图 3: 1D-CNN在独立测试集 T1 与 T2 上的预测可视化（D1-nonavg-multi-gs+na）。(a)–(b) T1的实测–预测散点图：乙酸（AA）与乙二醇（EG），每个物理样本聚合为单一数据点（同一样本同色），灰色阴影带表示1:1对角线的±5%偏离区间，误差棒为样本内重复测量预测的默认95%置信区间（正态分布，即均值 $\pm 1.96\sigma$）。(c)–(d) T2的按样本分组柱状图：真实浓度全为0，横向虚线标出真实值0，柱高为样本内预测均值，反映模型在该缺失环境下的预测偏移，误差棒为样本内95%置信区间。

的测试集上仍能保持良好表现；乙二醇则因本征拉曼强度本底较低、更易受到干扰，其外推精度明显下降。

单样本数据点个数的影响效果有限，可能源于两方面原因。其一，同一物理样本的多次重复测量之间的光谱变异主要来源于仪器噪声和样本定位误差，其变异性远小于不同化学环境之间的差异，因此无法提供足够丰富的正则化信号。其二，1D-CNN的卷积架构本身已具备一定的平移不变性和局部扰动鲁棒性，使得额外的重复测量带来的边际收益较小。这一发现与Bjerrum等人 [7]在近红外（near infrared, NIR）光谱中通过数据增强实现大幅提升的结果形成对比，提示数据增强策略的效用可能因光谱模态和测量条件而异。然而，仔细审视Bjerrum等人的结果可以发现：其数据增强与EMSC联用的最佳组合相较于非数据增强方案，Huber损失仅从1.91降至1.89，降幅极为有限，而RMSE反而从3.17升高至3.28，表明数据增强对模型性能的实际促进作用并不显著。这一结果与本文的结论在本质上是一致的——单样本数据点扩张所带来的边际收益较小。此外，Zarei等人 [6]的研究虽未深入探讨重复测量这一因素，但其在纯混合溶液条件下对每种浓度样本重复采集了60次光谱；根据本研究的经验，减弱样本间光谱测量不确定度通常仅需5–7次重复测量即可达到稳定，过多重复对预测精度的提升贡献极小。从这些观察中可提炼出一条实践指南：在设计拉曼定量分析的训练集时，应优先考虑纳入化学多样性丰富的**背景**物种——即使它们本身并非分析目标——只要其特征拉曼峰不与目标分析物的峰重叠即可。对特征峰位置的实验前检查（如辅助材料表 S1所示）可以指导此类辅助组分的选择。

分析路径的比较与选择

预处理策略 在所评估的八种预处理组合中，高斯背景校正结合面积归一化（gs-na）在验证和泛化两种机制下均是鲁棒性最强的策略（表 3）。该组合可能成功的原因在于：高斯平滑有效抑制高频仪器噪声，同时保留对浓度预测至关重要的宽光谱特征；面积归一化则缓解由仪器漂移和样本定位不一致引起的强度变化，且不扭曲相对峰强度。此外，本实验为模拟真实工业环境，光路与光强在多次测量中均有变动（如光强100–300的相对变动），在这种条件下gs-na仍能保持稳定，进一步印证了其在不同测量条件下的鲁棒性。值得警惕的是，若干在交叉折测试预测（CFT）表现良好的方法（如emsc+na、无预处理）在含有新化学物种的测试集上遭遇灾难性失败，表明某些预处理策略在泛化能力上存在局限性。这一观察与Zarei等人 [6]的发现一致——他们在土壤模拟体系中也报告了预处理策略对模型泛化的决定性影响，特别是在荧光干扰严重的情况下，合适的背景去除方法是模型成功的前提。

模型选择：PLS vs. 1D-CNN 在本研究评测的全部配置条件下，1D-CNN均一致且显著地优于PLS回归（表 2），尤其在向分布外测试样本的泛化方面表现突出（PLS在独立测试集上的Huber损失可达1D-CNN的2–6倍）。 PLS的线性潜变量假设虽然计算高效且可解释，但当底层光谱–浓度映射为非线性时（如氢键体系中的典型情况），对可实现的精度构成了基本上限。 1D-CNN的非线性特征提取能力，结合其卷积架构对局部光谱特征的平移不变性，使其能够捕捉PLS无法建模的复杂光谱–浓度关系。 Zarei等人 [6]也比较了PLSR与CNN，报告的结论是：经典偏最小二乘回归和卷积神经网络在信噪比较高的情况下性能上相当，这可能是因为所使用的CNN卷积层太多或没考虑外推泛化效果导致的。[21]和[6]同时报告了在噪声水平高的数据集中，CNN占上风，并据此得出结论：卷积神经网络具有从未经处理的含噪声光谱中自动提取浓度信息的潜力。本文虽未进行噪声条件下的测试，但从侧面印证了CNN的稳定性。此外，本结果与Bjerrum等人 [7]在近红外（NIR）光谱中的发现相似——CNN模型对未见样本的测试集泛化表现良好，表明这一模型选择规律在拉曼光谱与近红外光谱之间具有跨模态的相通性，反映了光谱分析大类中非线性模型在复杂体系中的普适优势。然而，如Herdt等人 [22]所报

告的，CNN模型在训练集上表现极佳但测试集过拟合严重的情况也时有发生，这可能源于训练策略的不当选择，例如未使用验证集进行早停监督、未采用交叉折测试预测（CFT）等。 Zhang等人 [23]也报告了CNN、ResNet-CNN等神经网络模型的预测效果优于PLS等传统方法，但因未采用严格的逐个批次的验证策略（batch-wise validation）进行比较，存在数据泄露风险，故无法直接印证本篇论文的结果。本研究中严格的交叉折测试预测（CFT）和早停协议有效避免了这一问题，确保了CNN泛化性能的可靠性。

单输出与多输出回归 输出维度的选择对模型的泛化行为产生了深刻影响。单输出模型虽在交叉折测试预测（CFT）上表现更好，但系统性地对训练分布过拟合：在含目标分析物的化学异质环境（测试集T1）上，其误差相对多输出模型普遍更高（乙酸约1.8–2.1倍；乙二醇约1.3倍，见 4）。多输出架构通过跨分析物的共享表示提供了隐式正则化，有效抑制了这一倾向；其对预测精度本征较差的分析物尤为有益——例如乙二醇在单输出下始终面临较高的外推误差，但在多输出设置下通过与乙酸共享表示，其在T1上的Huber损失（数据集1、2为6.98/6.91）明显低于单输出（9.14/8.81）。这一现象可归因于：在单输出设置下，模型可以**自由地**利用任何与单一目标分析物浓度相关的光谱特征（包括虚假相关性），而在多输出设置下，共享表示必须同时对多个分析物具有预测能力，从而约束模型只能学习具有真正诊断性的光谱特征 [24]。这一机制与Zarei等人工作中多氨基酸同时预测的设置具有方法论上的相似性——尽管他们的CNN模型本身采用多输出架构，但未系统比较单输出与多输出的差异，本研究填补了这一空白。

分析物特异性的预测差异

实验结果表明，不同分析物的拉曼定量预测精度差异显著，其根本原因在于各自拉曼特征峰的光谱质量——包括峰锐度、光谱隔离度和浓度–强度线性——存在本质性差异。就A组（四组分环境）而言，定量预测的难度由高到低大致为：乙酸 > 乙二醇 > 1,2-丙二醇 ≈ 聚乙二醇 200，其中1,2-丙二醇与聚乙二醇 200因特征峰重叠、本征拉曼强度较弱而难以被有效建模，故其预测结果仅在辅助材料中给出，正文仅对乙酸与乙二醇展开讨论。各化合物的特征拉曼峰位置及相对强度参见辅助材料表 S1。

值得注意的是，乙酸的优异表现是**跨评估机制稳健的**：在合适的配置下（如D1–D5配合gs-na、多输出），乙酸在交叉折测试预测（CFT）与两个外推测试集（T1、T2）上均保持在较低误差，其Huber损失稳定在约2.3–3.7区间，表现出显著的泛化可靠性。相比之下，乙二醇的预测能力呈现出**强烈的浓度依存性**：无论是在交叉折测试预测（CFT）还是外推测试集上，乙二醇都**仅对真实浓度接近0的样本表现优秀**——其在CFT零浓度子集上的Huber损失仅约0.8，在外推测试集T2（乙二醇真实值为0）上约为1.8；而一旦目标分析物浓度升高（CFT非零子集约8.6，外推测试集T1约6.9–10.7），预测精度便急剧退化。这一模式表明，乙二醇在本研究中只属于“只在缺失（零浓度）状态下可靠”的分析物，其正浓度区间的定量能力是薄弱的。这种“跨机制稳健的乙酸”与“浓度依存的乙二醇”的对比，揭示了分析物本征光谱质量对预测鲁棒性的决定性作用：当特征峰高度隔离且线性优良时（乙酸），模型能够在多样化学环境中保持稳定；而当该条件不满足时（乙二醇），模型只能在最触手可及、信号最平淡的零浓度情形下“看似可靠”。

图 4展示了本研究所用的六种有机液体在相同实验条件下的纯物质拉曼光谱（a），以及 AA → EG、AA → PEG200、AA → PG 三种混合溶液系列的光谱渐变对比（b–d）。

从光谱特征峰的角度可以解释上述精度差异：如果一个分析物在光谱区间内具有随浓度变化显著且与其他物质特征峰高度隔离的拉曼峰，则更容易实现准确预测。乙酸的892 cm^{-1} C–C伸缩振动

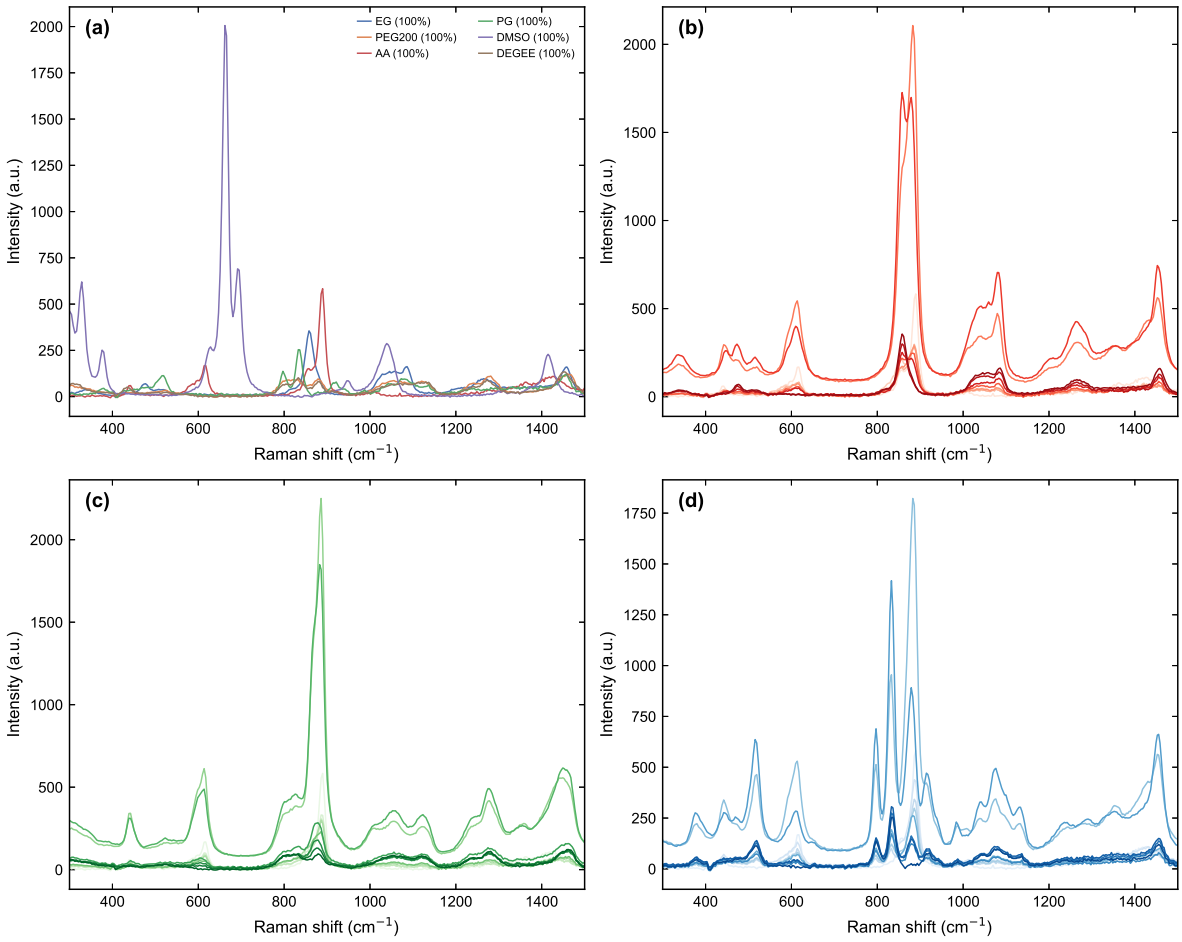


图 4: 拉曼光谱总览。(a) 六种有机液体在相同实验条件（相同激发光功率、相同光路）下的纯物质拉曼光谱对比，拉曼活性总体呈现 DMSO > AA > EG > PG > PEG200 ≈ DEGEE 的顺序；(b) AA → EG，深红色对应高浓度 EG、浅色对应高浓度 AA；(c) AA → PEG200，深绿色对应高浓度 PEG200；(d) AA → PG，深蓝色对应高浓度 PG。(b)–(d) 每图从深色到浅色表示过渡物质浓度逐步降低。

峰[25]在本实验中极其突出，与其他分析物的特征峰几乎无重叠，起到了准确预测的关键作用。值得注意的是，二甲亚砜的总体拉曼活性虽高于乙酸（如图 4(a)所示），但其定量预测性能却远不如后者——这一对比揭示了一个关键的方法论洞察：对于拉曼定量分析而言，特征峰的**锐度与光谱隔离程度**比总体拉曼活性更为关键。换言之，一个中等强度但孤立、尖锐的特征峰，比一个高强度但与邻近峰重叠的特征峰更适合作为定量分析的依据。

上述光谱学原理为实验前可行性评估提供了原则性基础：在无溶剂或共溶质干扰的光谱区间内具有孤立、高强度特征峰的目标分析物，本质上更适合进行准确的拉曼定量分析。

重复测量的不确定性与误差棒分析

前文预测可视化图（图 3与图 2）中的误差棒（$\pm 1.96\sigma$，即默认 95%置信区间）反映的是同一物理样本内多次重复测量所蕴含的预测不确定度，而非随机模拟或不同模型之间的差异。为量化这一不确定性来源，我们对样本内预测标准差（σ_{intra}）进行了统计：在数据集 D4、未平均化条件下，乙酸的均值约为 0.67 vol%，乙二醇约为 0.75 vol%，对应的平均 95%置信区间宽度约为± 1.3与± 1.5 vol%。这一量级远小于不同化学环境之间（如D1与 D5）的预测差异，也远小于模型在正浓度区间的系统误差。由此可推断，通过单纯增加重复测量次数来进一步压缩误差棒宽度的实际收益十分有限，这与此前**“单样本数据点个数的增加对泛化性能贡献较小”**的结论一致。

方法论启示与实践指南

综合以上两个方向的分析，本研究为复杂混合物拉曼定量分析的方法论设计提供了以下启示。

首先，在实验设计层面，训练数据集的化学构成应被视为与模型架构同等重要的设计变量。本研究表明，向训练集中引入化学多样性（即使新增组分并非分析目标）所提供的泛化收益，远大于同等规模的简单数据复制。这一发现对实际应用具有直接指导意义：在为拉曼定量分析准备标准样品时，应尽可能涵盖目标分析物在实际应用中可能遇到的主要背景物种，而非仅关注增加目标分析物自身的浓度梯度样本量。

其次，在分析路径选择层面，1D-CNN配合gs-na预处理、多输出架构构成了本研究中总体表现最优的组合方案。然而，不同的目标分析物可能受益于不同的预处理策略（如乙二醇在gs-nv下表现最佳），提示在实际应用中，理想的分析路径可能需要针对具体分析物进行微调。

第三，交叉折测试预测（CFT）作为模型选择和超参数调优的默认工具，在评估模型向化学异质性样本的泛化能力时存在根本性局限。本研究中多个预处理方法在交叉折测试预测（CFT）上表现优异，但在独立测试集上彻底失败，这一现象强调了在拉曼定量分析方法开发中纳入化学异质性独立测试集的必要性。

本研究存在若干局限性，提示了未来研究的方向。当前研究仅限于六种中等浓度的有机液体；扩展到更广泛的化学官能团、浓度范围（包括痕量检测）以及更复杂的基质（如水溶液、生物体液），将进一步检验本文结论的普适性。所采用的1D-CNN架构虽然有效，但相对简单——引入注意力机制、多尺度特征提取或物理信息正则化的更先进架构，可能带来进一步改进。此外，形式化的可解释性方法（如显著性映射和基于梯度的归因分析）超出了本文的研究范围，但它们是验证驱动模型预测的光谱特征是否对应于物理上有意义的拉曼谱带的下一个自然步骤。

结论

本研究以多组分有机溶液体系为实验平台，系统考察了分析路径与数据集配置两类方法论因素对拉曼光谱定量预测泛化能力的影响，并从光谱学原理与统计视角对所得结果进行了阐释。研究在六个有机液体、五种数据集配置、三类预处理维度与两种模型族构成的全矩阵下展开，旨在厘清各因素间的相对重要性及其交互效应。

关于分析路径，本研究表明高斯背景校正结合面积归一化（gs-na）在验证与泛化两种机制下均为鲁棒性最强的预处理策略（表 3）；1D-CNN在本研究评测的配置条件下均显著优于PLS，其独立测试集上的Huber损失仅为PLS的1/2–1/6（表 2）；多输出架构通过跨分析物的共享表示提供隐式正则化，有效抑制了单输出模型在含目标分析物的化学异质环境（测试集T1）上所观察到的过拟合（表 4、图 2）。尤为重要的是，这一机制使预测精度本征较差的乙二醇能够借助强预测分析物乙酸的表示信息，在T1上将其Huber损失（数据集1、2为6.98/6.91）降至单输出（9.14/8.81）之下，表明将弱预测溶质与强预测溶质耦合进同一多输出模型可显著提升弱溶质自身的预测效果。因此，1D-CNN配合gs-na预处理与多输出架构构成了本研究中总体最优的分析路径组合。

关于数据集配置，训练数据的规模与多样性在三个层面呈现出清晰的优先级：环境化学多样性 > 样本数 > 单样本数据点个数（表 5）。将训练化学环境从四组分扩展至六组分（D1–D3 vs. D4–D5）对原始目标分析物的预测精度产生了一致且显著的提升（聚合Huber损失下降约19%），而通过单样本数据点扩张（数据规模增至约5–6倍）仅带来不足8%的边际改善。值得注意的是，样本数本身的调整（如D1→D2、D4→D5）对性能影响很小，而环境化学多样性的变化（如D1 vs. D5）对性能影响巨大，表明上述提升更可能来源于化学多样性的扩展而非样本数量的增加。此外，目标分析物的本征拉曼活性是决定预测精度上限的关键物理化学因素：乙酸因具有强而尖锐的C–C伸缩谱带（图 4(a)），浓度–强度线性关系优良，在本研究评测的所有条件下均实现了最高的预测精度；而聚乙二醇因构象依赖的宽光谱特征构成了最大的定量挑战。更为关键的是，特征峰的锐度与光谱隔离程度比总体拉曼活性更能决定定量分析的可行性——一个孤立、尖锐的中等强度峰（如乙酸的892 cm^{-1}峰，其预测散点见图 2）比高强度但重叠的峰更适合作为定量依据。

综合以上发现，本研究为拉曼定量分析的方法论设计提出以下实践指南：其一，在分析具有重叠光谱特征的多组分混合物时，应优先采用1D-CNN等非线性模型；其二，当需要同时预测多种分析物时，宜采用多输出架构以利用跨分析物的隐式正则化；其三，预处理方法的选择必须通过在能够泛化的独立测试集上进行严格评估，而非仅依赖交叉折测试预测（CFT）；其四，应用涵盖多样化化学环境的样本丰富训练数据集以提升模型鲁棒性，即使额外组分本身并非分析目标；其五，优先选择具有孤立、尖锐拉曼特征峰的分析物作为定量目标。本研究亦存在若干局限性并提示了未来方向：当前研究仅限于六种中等浓度的有机液体，扩展到更广泛的化学官能团、浓度范围（包括痕量检测）以及更复杂的基质（如水溶液、生物体液）将进一步检验本文结论的普适性；所采用的1D-CNN架构相对简单，引入注意力机制、多尺度特征提取或物理信息正则化的更先进架构可能带来进一步改进；此外，形式化的可解释性方法（如显著性映射与基于梯度的归因分析）是验证驱动模型预测的光谱特征是否对应于物理上有意义拉曼谱带的下一个自然步骤。

Supporting Information

本工作支撑材料（投稿文件 `supporting_information.tex`）包括：成分物理化学依据、三种基线校正方法（AsLS/EMSC/Gaussian）的数学定义与参数、1D-CNN 网络结构与训练配置、异常值检测流程、训练–验证–测试协议，以及补充附图（图 S1–S7）与附表（表 S1–S3）等完整预测结果。

References

(1) Pelletier, M. J. *Applied Spectroscopy* **2003**, *57*, 20A–42A.

(2) Ryabchykov, O.; Guo, S.; Bocklitz, T. *Physical Sciences Reviews* **2018**, DOI: 10.1515/psr-2017-0043.

(3) Wold, S.; Sjöström, M.; Eriksson, L. *Chemometrics and Intelligent Laboratory Systems* **2001**, *58*, 109–130.

(4) Zhang, X.; Lin, T.; Xu, J.; Luo, X.; Ying, Y. *Analytica Chimica Acta* **2019**, *1058*, 48–57.

(5) Kiranyaz, S.; Avci, O.; Abdeljaber, O.; Ince, T.; Gabbouj, M.; Inman, D. J. *Mechanical Systems and Signal Processing* **2021**, *151*, 107398.

(6) Zarei, M.; Solomatova, N. V.; Aghaei, H.; Rothwell, A.; Wiens, J.; Melo, L.; Good, T. G.; Shokatian, S.; Grant, E. *Analytical Chemistry* **2023**, *95*, 15908–15916.

(7) Bjerrum, E. J.; Glahder, M.; Skov, T.

(8) Ma, C.; Zhang, Q.; Liang, J.; Yang, S.; Zhang, T.; Ruan, F.; Tang, H.; Li, H. *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy* **2024**, *318*, 124531.

(9) Wang, Y.; Chen, Z.; Liu, J.; Wang, H. *Journal of AOAC INTERNATIONAL* **2025**, *108*, 818–827.

(10) 李高荣; 吴密霞, 多元统计分析; 科学出版社: 北京, 2021.

(11) Yu, H. G.; Park, D. J.; Chang, D. E.; Nam, H. *Sensors* **2021**, *21*, DOI: 10.3390/s21248260.

(12) Fatayer, R.; Ahmed, W.; Szeto, I.; Sammut, S.-J.; Murugan, G. S. *ACS Measurement Science Au* **2026**, DOI: 10.1021/acsmeasuresciau.6c00099.

(13) Kapoor, S.; Narayanan, A. *Patterns* **2023**, *4*, DOI: 10.1016/j.patter.2023.100804.

(14) Lai, Y.-T.; Li, Y.-C.; Chen, Y.-F.; Cheng, J.-Y. *Microchemical Journal* **2025**, *212*, 113159.

(15) Joeres, R.; Blumenthal, D. B.; Kalinina, O. V. DataSAIL: Data Splitting Against Information Leakage, en, Pages: 2023.11.15.566305 Section: New Results, 2023.

(16) Huber, P. J. *The Annals of Mathematical Statistics* **1964**, *35*, 73–101.

(17) https://docs.pytorch.org/docs/2.13/nn.html#loss-functions.

(18) Prechelt, L. In *Neural Networks: Tricks of the Trade*, Orr, G. B., Müller, K.-R., Eds.; Springer: Berlin, Heidelberg, 1998, pp 55–69.

(19) Paszke, A.; Gross, S.; Massa, F.; Lerer, A.; Bradbury, J.; Chanan, G.; Killeen, T.; Lin, Z.; Gimelshein, N.; Antiga, L., et al. In *Advances in Neural Information Processing Systems*, 2019; Vol. 32, pp 8026–8037.

(20) Hu, X.; Chen, D.; Zhou, S.; Xu, J.; Xu, K.; Jiang, L.; Wang, Y.; Su, S.; Hu, S.; Xiang, J. *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy* **2026**, *351*, 127474.

(21) Antonio, P. et al. *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy* **2023**, TEMP PLACEHOLDER — TODO: replace with official bibliographic data.

(22) Herdt, D.; Teumer, T.; Keck, S. P.; Kunz, T.; Schiwek, V.; Kühnemuth, S.; Methner, F.-J.; Rädle, M. *Chemosensors* **2024**, *12*, 106.

(23) Zhang, Z.; Liang, Y.; Qin, X.; Jiao, X.; Lu, Z.; Su, Z.; Yang, M.; Li, C.; Wu, X.; Zeng, Q.; Li, B. *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy* **2026**, *355*, 127668.

(24) Borchani, H.; Varando, G.; Bielza, C.; Larrañaga, P. *WIREs Data Mining and Knowledge Discovery* **2015**, *5*, _eprint: https://wires.onlinelibrary.wiley.com/doi/pdf/10.1002/widm.1157, 216–233.

(25) Nucera, A.; Grillo, R.; Rizzuto, C.; Barberi, R. C.; Castriota, M.; Bürgi, T.; Caputo, R.; Palermo, G. *Biosensors* **2022**, *12*, DOI: 10.3390/bios12100895.

[TOC Graphic 占位：请在此放入图形摘要]

建议画布 3.25 in $\times$ 1.75 in，文字使用无衬线字体