支撑材料

基于拉曼光谱的多组分有机溶液定量分析：分析路径与数据集配置的效应

Haokai Yang[1] 与 Hongwang Lu[1]

[1]山东大学物理学院，山东济南，中国

通讯作者： lu@sdu.edu.cn

2026 年 9 月 9 日

支撑材料说明与索引

本支撑材料配合正文提供方法细节、补充图表以及完整数据结果，以支撑正文中的各项论断。各章节按正文的引用顺序组织：第 1 节给出成分物理化学依据；第 2 节给出三种基线校正方法的数学定义；第 3 节给出网络结构与训练配置；第 4 节给出异常值检测；第 5 节给出训练-验证-测试协议；第 6 节给出两类难以有效建模分析物及替代种子的预测结果。下文先给出附图、附表索引，随后逐一展开。

支撑材料附图索引。

编号	标题	状态
图 S1	1D-CNN 网络架构示意图	✓
图 S2	CNN 贝叶斯超参数优化结果	✓
图 S3	CNN 训练过程曲线	✓
图 S4	PLS 潜变量个数选择	✓
图 S5	重复性检验与相似度（马氏距离）异常值检测	✓
图 S6	PEG200 与 1,2-丙二醇预测散点图	✓
图 S7	独立测试集 T1/T2 预测可视化（另一种子）	✓

支撑材料附表索引。

编号	标题	状态
表 S1	六种有机化合物的特征拉曼峰	✓
表 S2	1D-CNN 贝叶斯优化超参数搜索空间	✓
表 S3	完整预测结果全貌表（Huber 损失）	✓

1 成分物理化学依据

在 2800–3000 cm^{-1} 波段，六种化合物同样存在强度较高的特征拉曼峰，主要对应 C–H 伸缩振动。然而，该波段对成分的区分度较弱：各化合物的 C–H 伸缩峰彼此高度重叠，且受分子间相互作用与溶剂效应的展宽影响，重复性不足，导致其用于定量训练的判别性不强、建模效果不佳。此外，1500–2800 cm^{-1} 区间的基线漂移会显著影响随后的归一化处理。因此，本研究将分析波段限定为 300–1500 cm^{-1} 的指纹区，以避免上述两方面的不利影响。

各化合物的特征拉曼峰位置及相对强度见表 S1，数据来源：SDBS [1]、Flanagan 等人 [2]。

本研究全部有效样本对应的浓度组合与样本编号匹配关系见补充数据集文件 `sample_concentration_136.csv`，该文件包含全部 136 个有效实验样本的配比参数与标签信息，为模型训练与异常值筛选的原始数据基准。

2 基线校正预处理方法

本文采用三种常用基线校正方法消除光谱低频背景与基线漂移，分别为自适应迭代最小二乘（AsLS）、扩展多元散射校正（EMSC）与高斯卷积基线校正（Gaussian）。各方法的原理、符号定义及参数设置如下。

2.1 自适应迭代最小二乘基线校正（AsLS）

AsLS 通过加权迭代最小二乘拟合平滑基线，可在保留特征峰的同时去除缓慢变化背景，其校正公式与基线优化目标函数为：

$$\vec{D_j}^{\,\mathrm{asls}} = \vec{D_j} - \vec{b_j} \tag{1}$$

$$\vec{b_j} = \arg\min_{\vec{b}} \left(\sum_i w_i (D_{ji} - b_i)^2 + \lambda \sum_i (\Delta^2 b_i)^2 \right) \tag{2}$$

式中：$\vec{D_j}$ 为第 j 条原始光谱；$\vec{b_j}$ 为拟合基线向量；w_i 为波段权重，由不对称系数 p 控制，当残差 $r_i = D_{ji} - b_i > 0$ 时 $w_i = p$，否则 $w_i = 1 - p$；λ 为平滑惩罚系数；Δ^2 为固定二阶差分算子。

参数设置：$\lambda = 1 \times 10^5$，$p = 0.01$，迭代次数 $n_{\mathrm{iter}} = 10$；基于 NumPy、SciPy 稀疏矩阵模块实现。

2.2 扩展多元散射校正（EMSC）

EMSC 以参考光谱为基准，拟合并消除光谱加性偏置、乘性缩放与多项式基线干扰，其模型与校正公式为：

$$\vec{D_j} \approx a_j + c_j \vec{R_{\mathrm{ref}}} + \sum_{m=1}^{M} h_{jm} \vec{P_m} \tag{3}$$

$$\vec{D_j}^{\,\mathrm{emsc}} = \frac{\vec{D_j} - a_j - \sum_{m=1}^{M} h_{jm} \vec{P_m}}{c_j} \tag{4}$$

式中：$\vec{R_{\mathrm{ref}}}$ 为参考光谱（默认取全体样本均值谱）；$\vec{P_m}$ 为第 m 阶多项式基线基函数；M 为基函数阶数；a_j 为加性偏置；c_j 为乘性缩放系数；h_{jm} 为基函数拟合系数。

参数设置：默认 $M = 2$，采用一阶、二阶归一化波数多项式为基函数；基于 NumPy 最小二乘模块实现。

2.3 高斯卷积基线校正（Gaussian）

该方法通过高斯核卷积提取光谱低频基线，原始光谱扣除基线得到校正后光谱，公式如下：

$$\vec{D_j}^{\,\text{gauss}} = \vec{D_j} - \vec{b_j} \tag{5}$$

$$\vec{b_j}[i] = \sum_{u=0}^{a} g_u \cdot D_j[i-u] \tag{6}$$

$$g_u = \frac{\exp\left(-\frac{(u-a/2)^2}{2\sigma^2}\right)}{\sum_{v=0}^{a}\exp\left(-\frac{(v-a/2)^2}{2\sigma^2}\right)} \tag{7}$$

式中：g_u 为归一化高斯卷积核权重；σ 为高斯核尺度，控制基线平滑度；卷积采用 `same` 模式以保持光谱维度不变。

参数设置：默认 $\sigma = 20.0$（$\sigma > 0$）；基于 SciPy 高斯窗函数与 NumPy 卷积运算实现。

3 网络结构部分

1D-CNN 网络拓扑如图 S1 所示：依次为两个一维卷积层（每层后接 ReLU 激活与最大池化）、Flatten 展平、全连接层，最后为输出层。多输出配置下，输出层维度与目标分析物数量匹配，并通过共享的表征层在不同分析物之间共享信息，从而抑制单输出模型中常见的过拟合。

训练配置如下：优化器为 `Adam`，最大训练轮次 `epochs = 500`，早停耐心值 `patience = 100`（基于验证集 Huber 损失），实现基于 PyTorch。损失函数统一为 Huber 损失（其与 Smooth L1 损失在默认阈值 $\delta = \beta = 1.0$ 下等价，见正文“损失函数与评估指标”一节）。超参数搜索空间见表 S2，各数据集配置下由贝叶斯优化（TPE）确定的最优超参数组合见正文“贝叶斯超参数优化”小节。

4 异常值检测部分

异常值检测分为两步：先基于光谱重复性进行无监督筛选，再结合模型预测残差进行有监督筛选。

4.1 重复性检验（无监督）

首先采用方向–尺度联合相似度算法（repeatability check）对预处理后光谱进行重复性检验与异常样本剔除。用于该检验的预处理流程为：波段 300–1500 cm^{-1} 窗口平滑（WS）、自适应迭代加权最小二乘基线校正（AsLS）与向量归一化（NV）。该流程通过量化单条重复光谱与样本均值光谱的方向一致性与幅值一致性，实现异常光谱的精准筛选。

设同一样本包含 n 条重复光谱向量 $\{\vec{D}_j\}_{j=1}^{n}$，首先计算样本均值参考光谱 $\bar{\vec{D}}$：

$$\bar{\vec{D}} = \frac{1}{n}\sum_{j=1}^{n}\vec{D}_j \tag{8}$$

通过余弦相似度计算光谱波形方向一致性 C_j，并引入极小扰动系数 $\varepsilon = 1.0 \times 10^{-12}$ 以规避除零误差：

$$C_j = \frac{\vec{D}_j^{\mathrm{T}}\,\bar{\vec{D}}}{\|\vec{D}_j\|\,\|\bar{\vec{D}}\| + \varepsilon} \tag{9}$$

基于向量二范数计算幅值尺度一致性 S_j，其中 $s_j = \|\vec{D}_j\|$ 为单条光谱范数，$\bar{s} = \|\bar{\vec{D}}\|$ 为均值光谱范数：

$$S_j = \frac{\min(s_j, \bar{s})}{\max(s_j, \bar{s})} \tag{10}$$

融合双维度相似度得到单条光谱综合一致性系数：

$$R_j = C_j \times S_j \tag{11}$$

统一设定异常判别阈值 $R_j < 0.97$：当单条光谱的综合一致性系数低于该阈值时，判定该光谱为异常数据并予以剔除。据此剔除异常样本 29，有效消除光谱采集过程中由波形畸变、幅值漂移带来的测量误差，保障数据集稳定性与可靠性。相似度评估的分布结果见图 S5。此类异常通常源于多次测量中某一次出现操作失误（如试管位置偏移、气泡或焦点漂移）等偶然因素。

4.2 有监督的异常值检测

在无监督剔除的基础上，对所有剩余数据施加高斯背景校正与向量归一化预处理，并借助 1D-CNN 模型进行交叉折测试预测（CFT），得到各样本的残差分布；随后采用多变量学生 t 分布分析 [3]，以 3σ 为检测阈值，剔除残差超限的样本。据此剔除的样本编号为 4、16、37、49、53 和 73。该类异常多源于样本溶液配制错误或其他系统性因素，残差在预测空间中表现为显著离群。

5 训练验证测试部分

所有模型统一采用交叉折测试预测（CFT）协议进行评估：将数据划分为 5 折，每一折轮流充当测试集，其余折用于训练与验证。本研究的样本规模约为 [4] 中 13 个样本的 10 倍，故未套用其给定的折分方案，而是改用固定随机种子下的确定性数据分割；同时，为避免纯随机分割导致某一折中某种浓度的零浓度样本占比过多、从而产生不典型的训练/验证/测试结果，本文采用 [5] 的相似度算法进行分组式数据分割（group-split）。

为防止光谱深度学习中的常见数据泄露 [6]，来自同一物理样本的重复光谱并不独立，故被合并至同一数据集，确保训练集、验证集与测试集的溶液配置完全互斥。对于外推测试集（T1、T2），将 5 折产生的 5 个模型分别独立预测，取简单算术平均作为该样本的最终预测结果；所有报告的测试集指标均基于此集成平均预测值计算。

6 预测结果部分

正文“预测可视化”与“检测限（LOD）与定量限（LOQ）”等小节已给出乙酸（e）与乙二醇（c）在各自最佳配置下的 CFT 预测散点图以及两个独立测试集（T1、T2）上的分布外预测表现，并对检测限（LOD/LOQ）与重复测量误差棒进行了分析。本部分补充两类正文未展开的内容。

首先，对难以有效建模的 1,2-丙二醇（k）与 PEG200（d），其 CNN 预测散点图见图 S6，实验配置与主文预测图一致（数据集 D4、未平均化、单输出、gs+na 预处理）。如正文讨论所述，二者特征峰与相邻组分高度重叠、且本征拉曼强度相对较弱，导致有效信号被高拉曼活性组分压制，难以被稳定建模。

其次，为说明随机种子对结果的稳健性，本文补充了另一随机种子下的独立测试集预测可视化（数据集 D1、未平均化、多输出、gs+na 预处理）见图 S7： (a)–(b) 为 T1 实测–预测散点图，同一物理样本以同色标出并聚合为单一数据点，误差棒为样本内重复测量预测的默认 95% 置信区间；(c)–(d) 为 T2 按物理样本分组的柱状图（真实浓度全为 0，横向虚线为真值 0），柱高为样本内预测均值。

各数据集、输出模式与平均化条件下的完整 Huber 损失汇总见表 S3。

7 附图

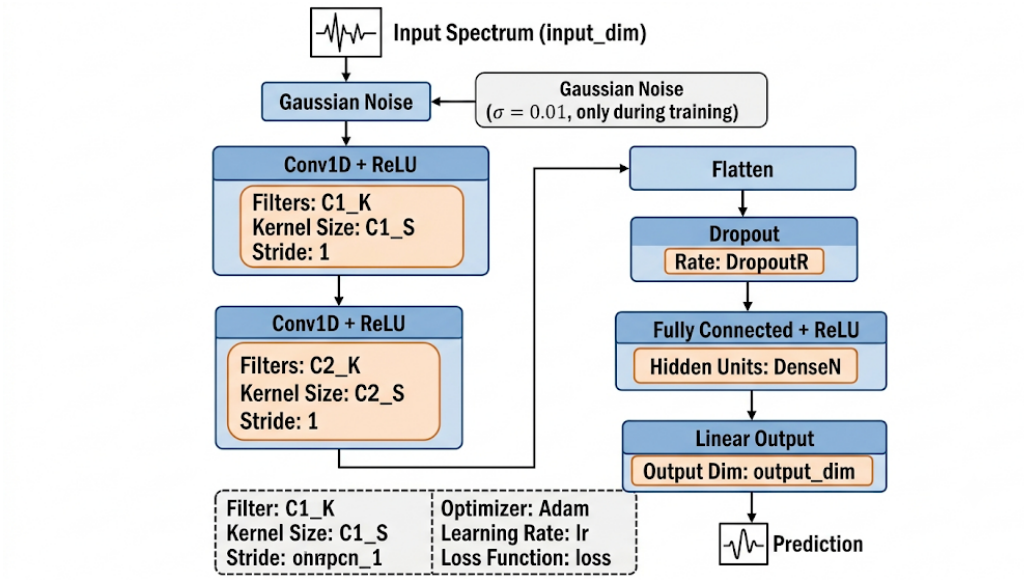


图 S1: 1D-CNN 网络架构示意图。包含两个一维卷积层（Conv1D），每层后接 ReLU 激活与最大池化（MaxPool1D），随后经 Flatten 展平后进入全连接层（Dense），最终输出目标分析物浓度预测值。多输出配置下输出层维度与目标分析物数量匹配。

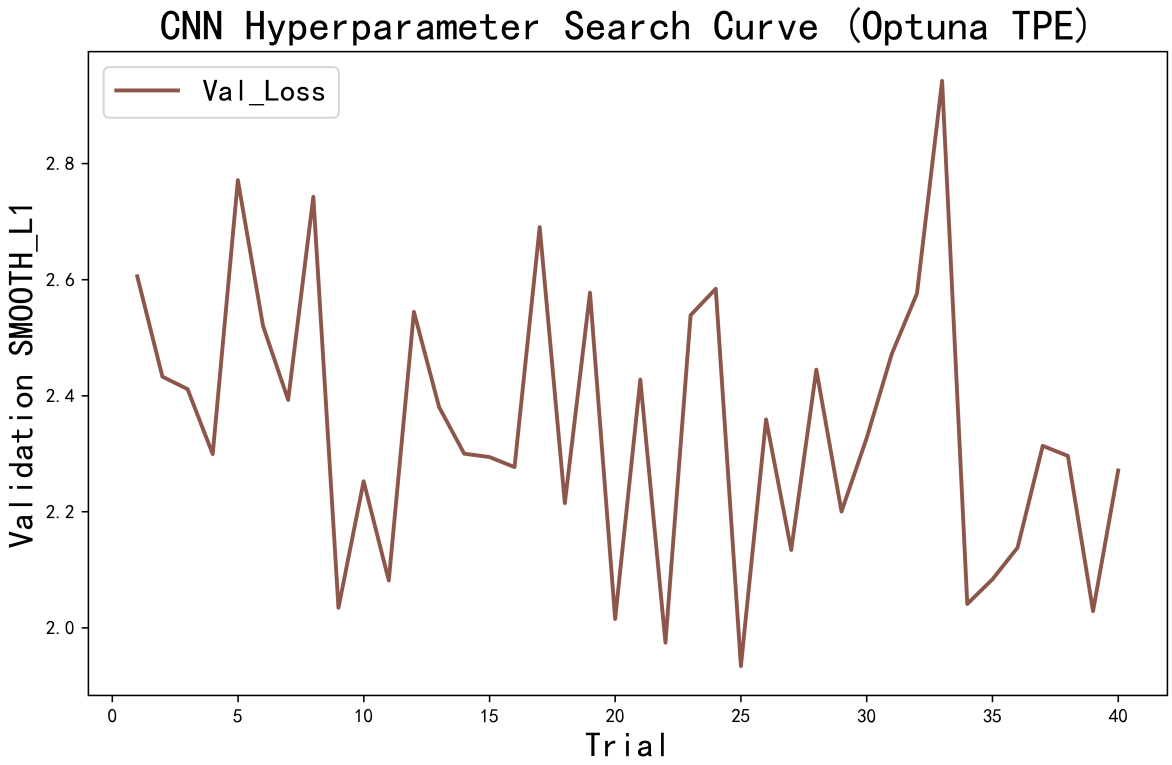


图 S2: 1D-CNN 贝叶斯超参数优化结果（数据集 D4、未平均化、单输出、asls+nv 预处理、Fold 02）。展示各超参数与优化目标（验证集 Huber 损失）之间的关系，包括参数重要性排序及 pairwise 依赖轮廓图。

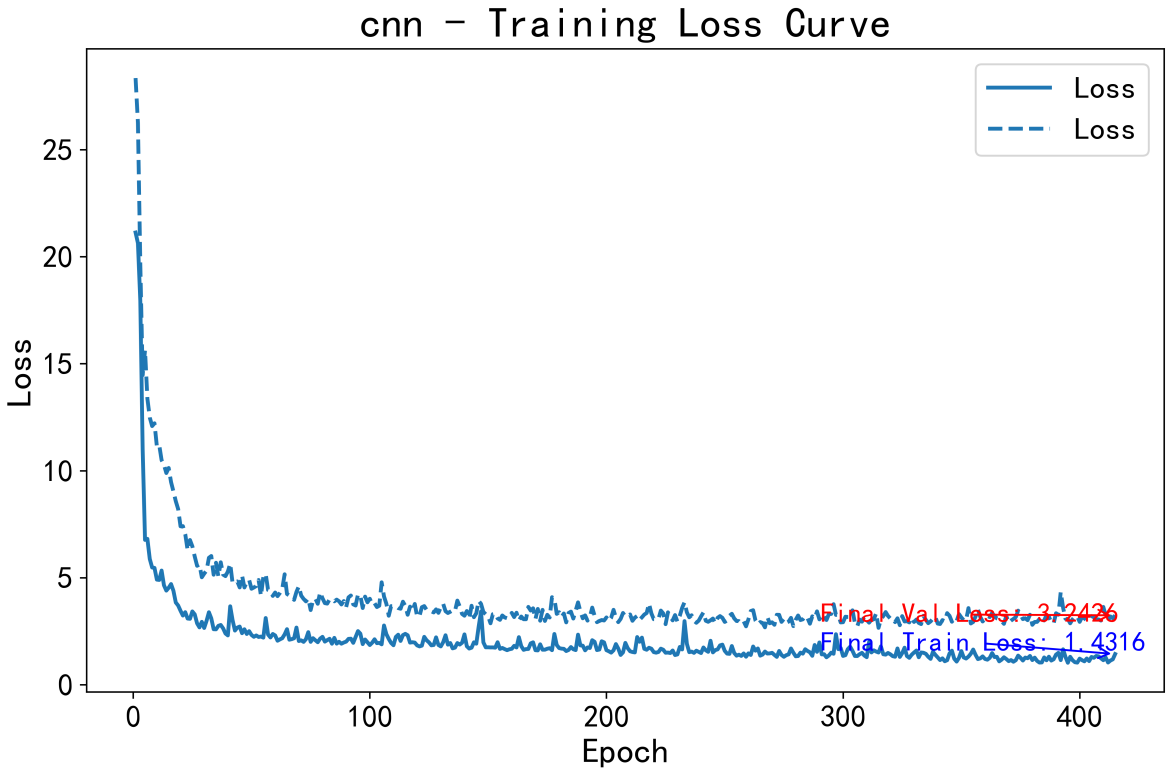


图 S3: 1D-CNN 训练过程曲线（数据集 D4、未平均化、单输出、gs+na 预处理、Fold 01）。展示训练集与验证集损失随 epoch 的变化趋势，以及早停触发点。

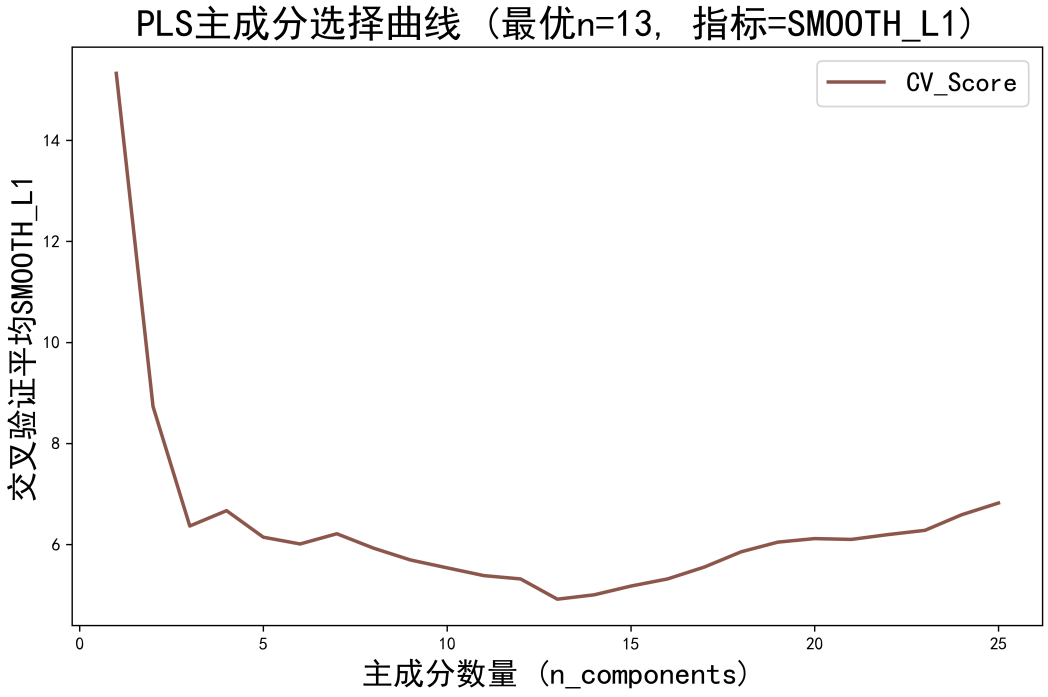


图 S4: PLS 潜变量个数选择（数据集 D4、未平均化、多输出、无预处理、Fold 01）。以验证集 Huber 损失为选择准则，展示损失随潜变量个数的变化曲线及最优值标记。

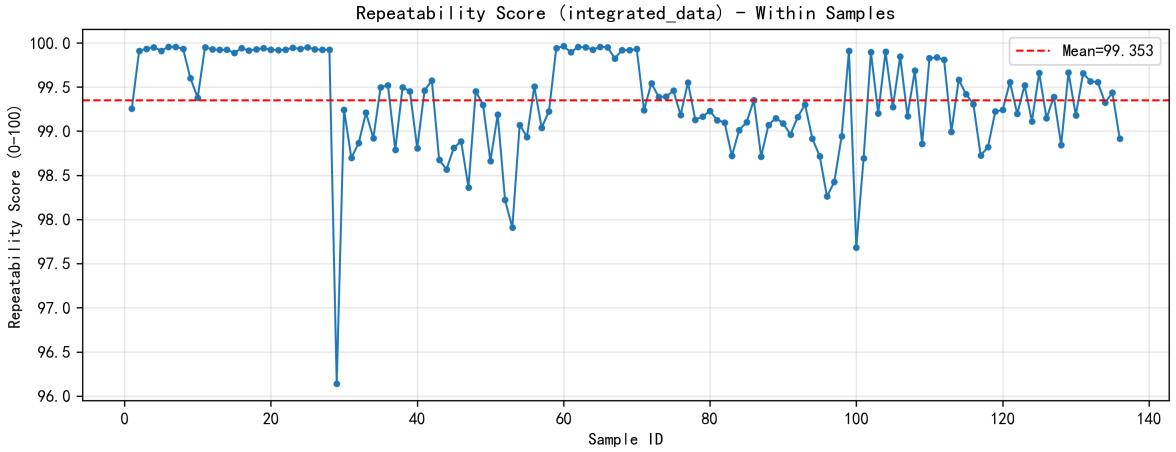


图 S5: 重复性检验与相似度异常值检测结果。展示各样本内重复光谱与样本均值光谱的方向–尺度综合一致性系数 R_j 分布；虚线为异常判别阈值 $R_j < 0.97$，据此剔除样本 29。

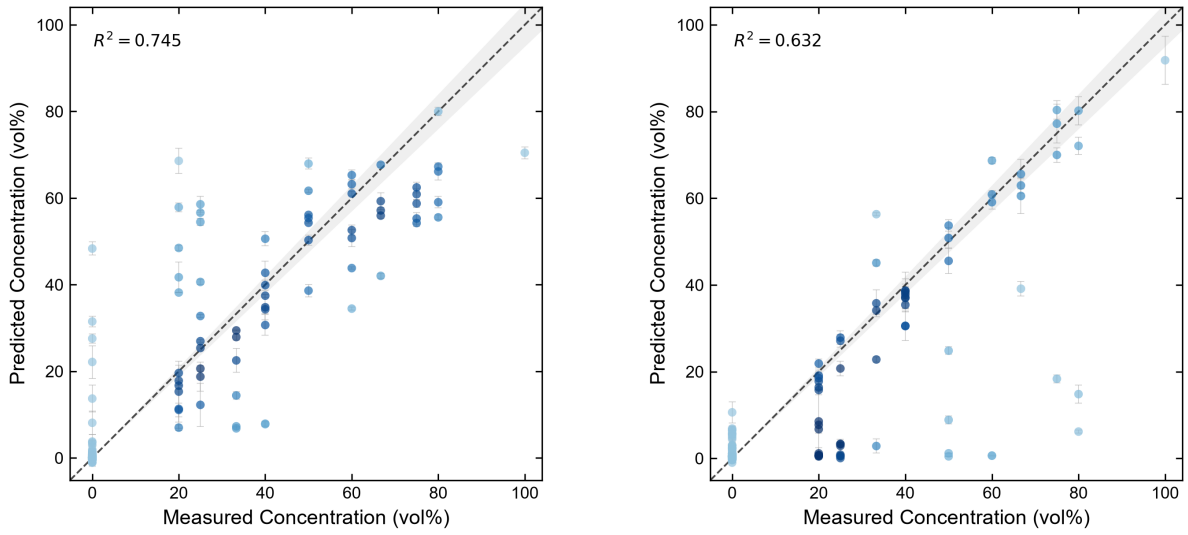


图 S6: PEG200（d）与 1,2-丙二醇（PG, k）的 CNN 预测散点图。实验配置与主文预测图一致：数据集 D4、未平均化、单输出 1D-CNN、gs+na 预处理。二者特征峰高度重叠且本征拉曼强度较弱，难以被有效建模，此处仅补充展示预测散点图与 R^2 统计值以供参考。

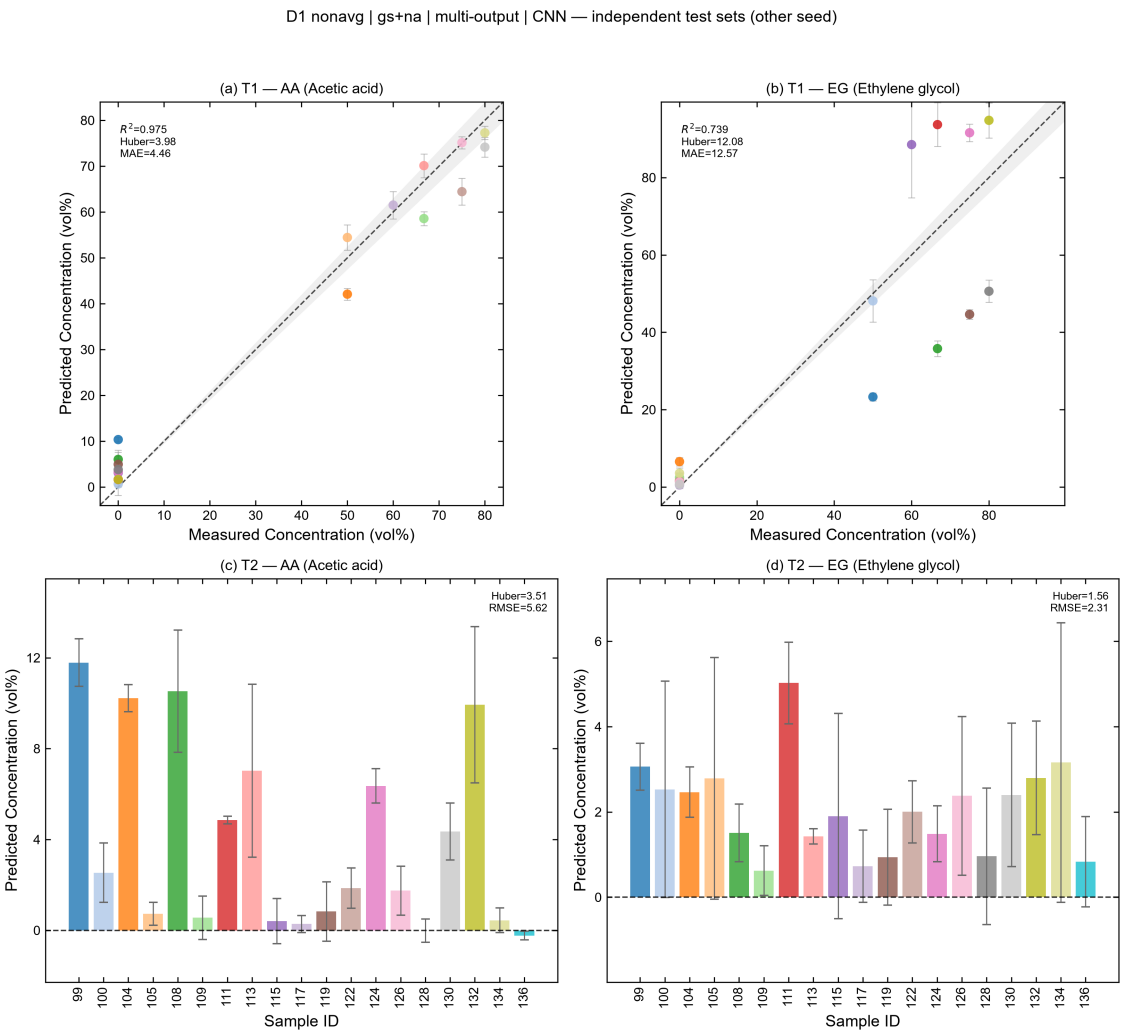


图 S7: 独立测试集 T1 与 T2 上的预测可视化（另一种子随机训练结果，D1-nonavg-multi-gs+na）。(a)–(b) T1 实测–预测散点图（乙酸 AA、乙二醇 EG），同一物理样本用同色标出，每个物理样本聚合为单一数据点，误差棒为样本内重复测量预测的 95% 置信区间；(c)–(d) T2 按物理样本分组的柱状图（真实浓度全为 0，横向虚线标出真值 0），柱高为样本内预测均值，误差棒为样本内 95% 置信区间。正文对应图展示了性能较好的种子结果，此处补充另一种子结果以说明随机稳健性。

8 附表

表 S1: 六种有机化合物的特征拉曼峰位置（cm^{-1}）及相对强度（%）。相对强度以各化合物最强峰为 100% 进行归一化。数据来源：SDBS [1] 与 Flanagan 等人 [2]。

化合物	特征峰位（$\mathbf{cm}^{-1}$）及相对强度（%）
乙酸 (AA)	2943 (86), 2253 (84), 892 (25, C–C 伸缩), 382 (11)
乙二醇 (EG)	2879 (90, C–H 伸缩), 1464 (40, CH_2 弯曲), 1271 (20), 1093 (37, C–O 伸缩), 1068 (28), 865 (77, C–C 伸缩), 462 (12)
1,2-丙二醇 (PG)	2974 (64), 2936 (96), 2881 (82), 1462 (31, CH_2/CH_3 弯曲), 925 (17), 842 (69, C–C 伸缩), 805 (27), 525 (25)
PEG 200	2930 (宽), 2880 (宽, C–H 伸缩), 1470 (宽, CH_2 弯曲), 1280 (宽), 1130 (宽, C–O–C), 860 (宽), 840 (宽)
二甲亚砜 (DMSO)	2997 (20), 2913 (70, C–H 伸缩), 1420 (11), 1045 (12, S=O 伸缩), 700 (39, C–S 伸缩), 670 (94, C–S 伸缩), 384 (11), 335 (25), 309 (15)
二乙二醇单乙醚 (DEGEE)	2977 (42), 2935 (93), 2875 (95, C–H 伸缩), 1463 (35, CH_2 弯曲), 890 (19), 845 (21), 444 (10)

表 S2: 1D-CNN 贝叶斯优化的超参数搜索空间。

参数名	类型	说明	范围
`DenseN`	`int` (step)	全连接层神经元数	[32, 128], step 16
`DropoutR`	`float`	Dropout 比率	[0.0, 0.1]
`C1_K`	`int` (step)	第一卷积层滤波器数	[2, 16], step 2
`C1_S`	`int` (step)	第一卷积层核大小	[4, 64], step 4
`C2_K`	`int` (step)	第二卷积层滤波器数	[4, 32], step 4
`C2_S`	`int` (step)	第二卷积层核大小	[4, 64], step 4
`learning_rate`	`float` (log)	Adam 学习率（对数均匀采样）	[0.0007, 0.003]
`batch_size`	`int` (step)	训练批次大小	[32, 64], step 16

表 S3: 完整预测结果全貌表（Huber 损失）。`nm`/`ns`/`am`/`as` 分别对应未平均化-多输出、未平均化-单输出、平均化-多输出、平均化-单输出。CNN 结果遵循正文规定的 `Best` 预处理规则，为随机种子 521 与 1314 两次训练的平均值；PLS 结果选取验证集 Huber 损失最低的潜变量数。表内“—”均出现在 T1/T2 外推集的 PLS 列，表示该 PLS 预测效果太差、未予展示（对比见正文“算法比较：PLS vs. 1D-CNN”一节），而非未开展评估。原始数据见 辅助材料 - 完整预测结果全貌表.csv。

分析物	数据集	PLS				1D-CNN			
		nm	**ns**	**am**	**as**	**nm**	**ns**	**am**	**as**
(a) 交叉折测试预测（CFT）									
乙酸	D1	4.12	3.73	3.98	3.50	3.32	2.70	3.38	3.06
乙酸	D2	4.21	4.12	4.43	3.95	3.53	2.84	3.91	3.49
乙酸	D3	4.30	3.44	4.10	3.61	3.70	3.15	3.98	3.27
乙酸	D4	4.11	3.60	4.15	3.69	2.67	2.34	2.68	2.57
乙酸	D5	3.88	3.74	4.10	3.86	2.56	2.26	2.79	2.67
乙二醇	D1	5.51	5.52	5.24	5.30	4.76	4.19	4.44	4.07
乙二醇	D2	6.06	6.04	5.37	5.31	4.41	4.12	4.56	4.03
乙二醇	D3	5.20	5.00	5.01	4.83	4.62	3.62	5.02	3.42
乙二醇	D4	5.50	5.22	5.71	5.55	3.67	3.51	3.84	3.52
乙二醇	D5	5.66	5.71	5.84	5.62	3.69	3.54	3.98	3.37
(b) 外推测试集 T1									
乙酸	D1	8.27	12.69	—	—	3.62	6.37	2.75	4.19
乙酸	D2	—	—	—	—	2.45	5.04	4.97	4.73
乙酸	D3	—	—	—	—	6.59	5.68	9.01	7.96
乙二醇	D1	10.35	10.51	—	—	6.98	9.14	9.04	8.14
乙二醇	D2	—	—	—	—	6.91	8.81	9.23	8.71
乙二醇	D3	—	—	—	—	12.94	11.85	12.19	13.49
(c) 外推测试集 T2									
乙酸	D1	6.22	6.94	—	—	2.98	0.87	2.22	0.99
乙酸	D2	—	—	—	—	2.47	1.45	5.76	4.45
乙酸	D3	—	—	—	—	16.63	9.99	18.54	14.09
乙二醇	D1	9.49	9.50	—	—	1.81	2.84	1.63	1.72
乙二醇	D2	—	—	—[12]	—	3.63	3.75	5.33	4.98
乙二醇	D3	—	—	—	—	14.14	12.22	14.55	14.19

References

(1) National Institute of Advanced Industrial Science and Technology (AIST) Spectral Database for Organic Compounds (SDBS), https://sdbs.db.aist.go.jp, Accessed: 2026-08-04.

(2) Flanagan, A. R.; Glavin, F. G. *Scientific Data* **2025**, *12*, 498.

(3) 李高荣; 吴密霞, 多元统计分析; 科学出版社: 北京, 2021.

(4) Lai, Y.-T.; Li, Y.-C.; Chen, Y.-F.; Cheng, J.-Y. *Microchemical Journal* **2025**, *212*, 113159.

(5) Joeres, R.; Blumenthal, D. B.; Kalinina, O. V. DataSAIL: Data Splitting Against Information Leakage, en, Pages: 2023.11.15.566305 Section: New Results, 2023.

(6) Kapoor, S.; Narayanan, A. *Patterns* **2023**, *4*, DOI: 10.1016/j.patter.2023.100804.